ĐẠI HỌC QUỐC GIA TP. HCM

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

TRẦN BẢO TÍN

GIẢI PHÁP CHẨN ĐOÁN NGUY CƠ KHÔNG HOÀN THÀNH KHOÁ HỌC MOOC DỰA TRÊN HÀNH VI HỌC TẬP

LUẬN VĂN THẠC SĨ

TP. Hồ Chí Minh – Năm 2026

ĐẠI HỌC QUỐC GIA TP. HCM

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

TRẦN BẢO TÍN

GIẢI PHÁP CHẨN ĐOÁN NGUY CƠ KHÔNG HOÀN THÀNH KHOÁ HỌC MOOC DỰA TRÊN HÀNH VI HỌC TẬP

Ngành: Hệ Thống Thông Tin

Mã số ngành: 8480101

NGƯỜI HƯỚNG DẪN KHOA HỌC

HDC: TS. Nguyễn Trần Minh Thư

TP. Hồ Chí Minh – Năm 2026

LỜI CAM ĐOAN

Tôi cam đoan luận văn thạc sĩ ngành Hệ Thống Thông Tin, với đề tài *"Giải pháp Chẩn đoán nguy cơ không hoàn thành khoá học MOOC dựa trên hành vi học tập"* là công trình do tôi thực hiện dưới sự hướng dẫn của TS. Nguyễn Trần Minh Thư.

Các kết quả nghiên cứu trình bày trong luận văn là trung thực và chính xác. Mọi tài liệu, số liệu và kết quả của các tác giả khác được sử dụng trong luận văn đều được trích dẫn đầy đủ và chỉ rõ nguồn gốc theo đúng quy định. Bộ dữ liệu MOOCCubeX được sử dụng là dữ liệu công khai phục vụ mục đích nghiên cứu học thuật.

Học viên cao học
(Ký và ghi rõ họ tên)

TRẦN BẢO TÍN

LỜI CẢM ƠN

Trước hết, tôi xin bày tỏ lòng biết ơn sâu sắc đến TS. Nguyễn Trần Minh Thư – người đã trực tiếp hướng dẫn, định hướng khoa học và đồng hành cùng tôi trong suốt quá trình thực hiện luận văn. Những góp ý sắc bén về phương pháp luận, về cách đặt vấn đề và về tính chặt chẽ của thực nghiệm đã giúp tôi hình thành nên quan điểm thiết kế xuyên suốt của luận văn này.

Tôi xin chân thành cảm ơn Quý Thầy Cô Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Thành phố Hồ Chí Minh đã truyền đạt cho tôi những kiến thức nền tảng và chuyên sâu trong suốt chương trình đào tạo trình độ thạc sĩ. Tôi cũng xin cảm ơn Phòng Đào tạo Sau đại học đã tạo điều kiện thuận lợi về mặt thủ tục và học vụ.

Tôi xin gửi lời cảm ơn đến nhóm tác giả của bộ dữ liệu MOOCCubeX vì đã công khai một nguồn tài nguyên quý giá cho cộng đồng nghiên cứu phân tích học tập, nhờ đó luận văn này mới có cơ sở dữ liệu để tiến hành thực nghiệm ở quy mô lớn.

Cuối cùng, tôi xin dành lời cảm ơn đặc biệt đến gia đình, bạn bè và đồng nghiệp đã luôn động viên, hỗ trợ tôi cả về tinh thần lẫn thời gian để tôi có thể hoàn thành luận văn này.

TP. Hồ Chí Minh, năm 2026

Học viên cao học

TRẦN BẢO TÍN

Mục lục

LỜI CAM ĐOAN i

LỜI CẢM ƠN ii

DANH MỤC CÁC TỪ VIẾT TẮT ix

TRANG THÔNG TIN LUẬN VĂN xi

THESIS INFORMATION xiii

CHƯƠNG 1. MỞ ĐẦU 1

Giới thiệu tóm tắt về đề tài 1

Lý do lựa chọn đề tài 1

Mục tiêu nghiên cứu 2

Đối tượng và phạm vi nghiên cứu 3

Phương pháp nghiên cứu 3

Ý nghĩa thực tiễn của đề tài 4

Đóng góp chính của luận văn 4

Bố cục của luận văn 5

CHƯƠNG 2. TỔNG QUAN VỀ ĐỀ TÀI 6

2.1 Bối cảnh và phát biểu vấn đề 6

2.1.1 Hiện tượng bỏ học trong MOOC 6

2.1.2 Dự báo bỏ học trong bối cảnh phân tích học tập 6

2.1.3 Vì sao cần phân biệt nhiều mức rủi ro 7

2.2 Tiêu chí khảo sát tài liệu 7
2.2.1 Sự tiến hóa của lĩnh vực qua ba giai đoạn 8
2.2.2 Hai bộ dữ liệu chuẩn của lĩnh vực 9
2.3 Họ phương pháp 1: Học máy truyền thống và tối ưu hóa 9
2.3.1 Các mô hình nền móng 9
2.3.2 Tích hợp khả năng giải thích 10
2.3.3 Tối ưu hóa lựa chọn đặc trưng và siêu tham số 10
2.3.4 Phân tích chi tiết phương pháp luận của họ thứ nhất 11
2.4 Họ phương pháp 2: Học sâu và tiếp cận dựa trên đồ thị 11
2.4.1 Mô hình chuỗi thời gian 11
2.4.2 Một kết luận cảnh báo: học sâu không phải lúc nào cũng vượt trội 12
2.4.3 Mở rộng sang nhãn đa mức và mô hình đồ thị 12
2.4.4 Phân tích chi tiết phương pháp luận của họ thứ hai 13
2.5 Phân tích hiện trạng và khoảng trống nghiên cứu 14
2.6 Định vị thiết kế của khung đề xuất 16
2.7 Kết luận chương 17

CHƯƠNG 3. PHƯƠNG PHÁP THỰC HIỆN ĐỀ TÀI 18

3.1 Cơ sở lý thuyết 18
3.1.1 Học có giám sát và bài toán phân loại 18
3.1.2 Bài toán phân loại có thứ tự 19
3.1.3 Mạng nơ-ron hồi quy và LSTM 19
3.1.4 BiLSTM: LSTM hai chiều 20
3.1.5 GRU và cơ chế chú ý nhẹ 21
3.1.6 Chiến lược điền giá trị thiếu 22
3.1.7 Hàm mất mát cho dữ liệu mất cân bằng 23

3.1.8 Hàm softmax và diễn giải xác suất 24
3.1.9 Quá khớp, chính quy hóa và tính tổng quát 24
3.1.10 Các chỉ số đánh giá 25
3.1.11 Về tính có ý nghĩa thống kê và khả năng tái lập 26
3.1.12 Các mô hình baseline học máy truyền thống 26
3.1.13 Đặc điểm dữ liệu MOOC và tín hiệu hành vi theo tuần 27
3.2 Phát biểu và mô hình hóa bài toán 27
3.3 Kiến trúc khung EarlyRisk-MOOC 30
3.3.1 Ba nguyên tắc thiết kế 30
3.3.2 Năm tầng xử lý 30
3.3.3 Quy trình huấn luyện và tối ưu hóa 31
3.3.4 Phân tích độ phức tạp tính toán 32
3.3.5 Chi tiết cấu hình các mô hình 32
3.4 Tổng hợp quy trình thành thuật toán 33

CHƯƠNG 4. KẾT QUẢ ĐỀ TÀI VÀ PHÂN TÍCH, ĐÁNH GIÁ, THẢO LUẬN 35

4.1 Thiết lập thực nghiệm 35
4.1.1 Bộ dữ liệu và quy trình lọc cohort 35
4.1.2 Quy tắc gán nhãn và giao thức chia tập 36
4.1.3 Tái hiện sáu baseline trên cùng giao thức 37
4.1.4 Hạ tầng xử lý dữ liệu lớn và quy trình ETL 37
4.2 Kết quả đối sánh với sáu baseline 38
4.2.1 Phân tích chi phí–hiệu năng theo lát cắt Pareto 40
4.2.2 Phân tích lỗi và hành vi của các baseline 41
4.2.3 Kết quả mở rộng: Weighted-F1 và AUC-OVR 42
4.3 Thực nghiệm nội tại của EarlyRisk-MOOC 43

4.3.1 Phân tích ma trận nhầm lẫn 44
4.3.2 Phân tích sâu theo cửa sổ quan sát 45
4.3.3 Ý nghĩa của khoảng cách hiệu năng so với baseline 45
4.4 Thảo luận 46
4.4.1 Ý nghĩa lý thuyết và thực tiễn 46
4.4.2 Đối chiếu với công trình gần nhất 47
4.4.3 Cân nhắc về đạo đức và quyền riêng tư 48
4.4.4 Về khả năng giải thích của mô hình 48
4.4.5 Giới hạn và hướng nghiên cứu tiếp theo 48
4.4.6 Hàm ý cho triển khai thực tế 50
4.4.7 Vai trò của phân tích Pareto trong việc chọn điểm vận hành . 50
4.5 Kết luận chương 51

CHƯƠNG 5. KẾT LUẬN VÀ KIẾN NGHỊ **52**

Kết luận 52
Tổng hợp trả lời các câu hỏi nghiên cứu 53
Kiến nghị và hướng nghiên cứu tiếp theo 54

DANH MỤC TÀI LIỆU THAM KHẢO **55**

PHỤ LỤC **59**

Phụ lục A. Danh mục đầy đủ các đặc trưng đầu vào 59
Phụ lục B. Siêu tham số chính của khung 59
Phụ lục C. Phân công đóng góp (CRediT) 60

DANH MỤC CÁC HÌNH, BIỂU ĐỒ

3.1 Kiến trúc khung EarlyRisk-MOOC với năm tầng. Tầng 1 lọc người học có hoạt động thực sự từ MOOCCubeX. Tầng 2 trích xuất đặc trưng và tạo cửa sổ chống rò rỉ. Tầng 3 đối sánh bốn chiến lược điền giá trị thiếu. Tầng 4 huấn luyện hai bộ trích xuất chuỗi với hai hàm mất mát. Tầng 5 sinh xác suất và điểm rủi ro phục vụ xếp hạng can thiệp. 31

4.1 Mặt tiền Pareto giữa Macro-F1 và Runtime (giây) ở cửa sổ W2. Kim cương đỏ là EarlyRisk-MOOC tại W1/W2/W4. Cấu hình W2 (khuyến nghị) đạt Macro-F1 = 0,9835 với Runtime = 76,5 giây. Aouarib ở W4 (GA-XGB, 951,6 giây) nằm ngoài phạm vi trục hoành và không được vẽ. 40

DANH MỤC CÁC BẢNG SỐ LIỆU

2.1 Tổng hợp 19 công trình tiêu biểu về dự báo bỏ học theo bộ tiêu chí thống nhất 15

2.2 Định vị thiết kế của EarlyRisk-MOOC so với các công trình khảo sát (✓: có; △: một phần; ×: không) 17

4.1 Thống kê chi tiết cohort thực nghiệm sau khi lọc từ MOOCCubeX . . 36

4.2 Chi tiết tái hiện 6 công trình baseline trên cùng giao thức của EarlyRisk-MOOC 37

4.3 So sánh định lượng EarlyRisk-MOOC với 6 công trình tái hiện trên MOOCCubeX (nhãn 5 mức, cohort 100.409 cặp, split 8:1:1, seed = 42) 39

4.4 Chỉ số mở rộng tại cửa sổ W2 cho các hệ thống tiêu biểu 42

4.5 Kết quả thực nghiệm nội tại của EarlyRisk-MOOC theo cửa sổ quan sát 43

4.6 Ma trận nhầm lẫn của cấu hình W2 + KNN + BiLSTM trên tập kiểm tra (giá trị minh họa theo tỷ lệ phần trăm hàng) 44

A.1 Chín đặc trưng hành vi theo tuần ($\mathbf{b}_i^{(t)} \in \mathbb{R}^9$) 59

B.1 Các siêu tham số chính sử dụng trong thực nghiệm 59

DANH MỤC CÁC TỪ VIẾT TẮT

Từ viết tắt	Diễn giải
AUC	Area Under the Curve (Diện tích dưới đường cong)
AUC-OVR	Area Under the Curve – One-vs-Rest
BiLSTM	Bidirectional Long Short-Term Memory
CB-Focal	Class-Balanced Focal Loss
CLS	Column-Level Security
CNN	Convolutional Neural Network (Mạng nơ-ron tích chập)
DL	Deep Learning (Học sâu)
ETL	Extract – Transform – Load
GA	Genetic Algorithm (Giải thuật di truyền)
GB	Gradient Boosting
GCN	Graph Convolutional Network (Mạng tích chập đồ thị)
GRU	Gated Recurrent Unit
HVCH	Học viên cao học
KNN	K-Nearest Neighbors (K láng giềng gần nhất)
LR	Logistic Regression (Hồi quy logistic)
LSTM	Long Short-Term Memory
ML	Machine Learning (Học máy)
MLP	Multi-Layer Perceptron
MOOC	Massive Open Online Course (Khóa học trực tuyến mở quy mô lớn)

Từ viết tắt	Diễn giải
RF	Random Forest (Rừng ngẫu nhiên)
RNN	Recurrent Neural Network (Mạng nơ-ron hồi quy)
SHAP	SHapley Additive exPlanations
SVM	Support Vector Machine (Máy vector hỗ trợ)
TCN	Temporal Convolutional Network
XAI	eXplainable Artificial Intelligence (Trí tuệ nhân tạo giải thích được)
XGBoost	eXtreme Gradient Boosting

TRANG THÔNG TIN LUẬN VĂN

Tên đề tài luận văn: Giải pháp Chẩn đoán nguy cơ không hoàn thành khoá học MOOC dựa trên hành vi học tập

Ngành: Hệ Thống Thông Tin

Mã số ngành: 8480101

Họ tên học viên cao học: TRẦN BẢO TÍN

Khóa đào tạo: 34/2024

Người hướng dẫn khoa học: TS. Nguyễn Trần Minh Thư

Cơ sở đào tạo: Trường Đại học Khoa học Tự nhiên, ĐHQG.HCM

1. TÓM TẮT NỘI DUNG LUẬN VĂN:

Sự bùng nổ của các khóa học trực tuyến mở quy mô lớn (MOOC) mang lại cơ hội tiếp cận giáo dục bình đẳng nhưng đối diện thách thức nghiêm trọng về tỷ lệ hoàn thành thấp (5–15%). Dự báo sớm người học có nguy cơ bỏ học là điều kiện cần để can thiệp kịp thời. Luận văn đề xuất *EarlyRisk-MOOC* – một khung dự báo sớm đa cửa sổ trên ba thời điểm W1, W2 và W4 (1, 2 và 4 tuần đầu khóa học), với 48 cấu hình hoán đổi có kiểm soát giữa các chiến lược điền giá trị thiếu, hai bộ trích xuất chuỗi và hai hàm mất mát. Bài toán được đặt dưới dạng phân loại nhãn rủi ro có thứ tự A/B/C/D/E thay cho nhãn nhị phân truyền thống. Thực nghiệm trên bộ dữ liệu MOOCCubeX với 100.409 cặp người học–khóa học (trung bình 5 hạt giống ngẫu nhiên) cho thấy cấu hình W2 + KNN + BiLSTM + cb_focal đạt Macro-F1 = 0,9835 và $F1_D$ = 0,9914.

2. NHỮNG KẾT QUẢ MỚI CỦA LUẬN VĂN:

- Thiết kế bài toán nhãn 5 mức có thứ tự thay cho nhãn nhị phân, bảo toàn được tín hiệu phân biệt nhóm "đang hoạt động nhưng rủi ro cao" với nhóm "đã rời khóa".
- Khung benchmark đa cửa sổ thống nhất: cùng cohort, cùng quy tắc nhãn, cùng giao thức chia tập 8:1:1 cho mọi cấu hình.

- Tái hiện sáu công trình tiêu biểu trên cùng giao thức, tạo cơ sở so sánh có ý nghĩa thống kê; cấu hình đề xuất dẫn đầu ở cả ba cửa sổ W1/W2/W4 và vượt baseline tốt nhất 13,9% điểm Macro-F1 tại W2.
- Định danh điểm vận hành cân bằng W2 + KNN + BiLSTM + cb_focal, giữ 99,1% chất lượng của W4 với chi phí thời gian thấp hơn 29,2%.

3. CÁC ỨNG DỤNG/ KHẢ NĂNG ỨNG DỤNG TRONG THỰC TIỄN HAY NHỮNG VẤN ĐỀ CÒN BỎ NGỎ CẦN TIẾP TỤC NGHIÊN CỨU:

Khung có thể tích hợp vào hệ thống quản lý học tập để cảnh báo sớm và xếp hạng ưu tiên can thiệp. Hướng nghiên cứu tiếp theo bao gồm mở rộng cohort lên toàn bộ MOOCCubeX, kiểm chứng tính tổng quát theo giao thức hold-out theo khóa học, tích hợp meta-history của người học, và đánh giá hiệu ứng can thiệp thực tế qua thử nghiệm A/B.

TẬP THỂ CÁN BỘ HƯỚNG DẪN	HỌC VIÊN CAO HỌC
TS. Nguyễn Trần Minh Thư	TRẦN BẢO TÍN

XÁC NHẬN CỦA CƠ SỞ ĐÀO TẠO

HIỆU TRƯỞNG

THESIS INFORMATION

Thesis title: A Diagnostic Model for Identifying MOOC Non-Completion Risk Based on Learning Behavior Analysis

Speciality: Computer Science

Code: 8480101

Name of Master Student: Tran Bao Tin

Academic year: 34/2024

Supervisor: Dr. Nguyen Tran Minh Thu

At: VNUHCM – University of Science

1. SUMMARY:

The proliferation of Massive Open Online Courses (MOOCs) offers equitable access to education but faces a critical retention challenge, with completion rates of only 5–15%. Early prediction of at-risk learners is a prerequisite for timely intervention. This thesis proposes *EarlyRisk-MOOC*, a unified multi-window early-prediction framework spanning three observation points W1, W2 and W4 (the first 1, 2 and 4 weeks), benchmarking 48 controlled configurations across missing-value imputation strategies, two sequence encoders and two loss functions. The task is cast as ordinal risk classification over five levels A/B/C/D/E rather than the conventional binary label. Experiments on MOOCCubeX (100,409 learner–course pairs, averaged over 5 random seeds) show the W2 + KNN + BiLSTM + cb_focal configuration achieves a Macro-F1 of 0.9835 and $F1_D$ of 0.9914.

2. NOVELTY OF THESIS:

- A five-level ordinal label design that preserves the distinction between "active but high-risk" and "already dropped-out" learners.
- A unified multi-window benchmark applying the same cohort, labeling rule and 8:1:1 split protocol to every configuration.

- Faithful reproduction of six representative baselines under one protocol, enabling statistically meaningful comparison; the proposed configuration leads at all three windows W1/W2/W4 and surpasses the strongest baseline by 13.9% Macro-F1 at W2.
- Identification of a balanced operating point (W2 + KNN + BiLSTM + cb_focal) retaining 99.1% of W4 quality at 29.2% lower runtime.

3. APPLICATIONS/ APPLICABILITY/ PERSPECTIVE:

The framework can be integrated into learning management systems for early warning and intervention prioritization. Future directions include scaling the cohort to the full MOOCCubeX, validating generalizability under course-level hold-out protocols, integrating learner meta-history, and evaluating real intervention effects via A/B testing.

SUPERVISOR	**MASTER STUDENT**
Dr. Nguyen Tran Minh Thu	Tran Bao Tin

CERTIFICATION
UNIVERSITY OF SCIENCE

PRESIDENT

CHƯƠNG 1. MỞ ĐẦU

1. Giới thiệu tóm tắt về đề tài

Các khóa học trực tuyến mở quy mô lớn (*Massive Open Online Courses* – MOOC) đã trở thành một thành phần quan trọng của hệ sinh thái giáo dục số trong hơn một thập kỷ qua. Với khả năng phục vụ đồng thời hàng chục nghìn người học trên một nền tảng duy nhất, MOOC mở rộng đáng kể khả năng tiếp cận giáo dục đại học, xóa nhòa rào cản địa lý và chi phí [1]. Tuy nhiên, đi cùng với tiềm năng to lớn đó là một nghịch lý dai dẳng: tỷ lệ hoàn thành khóa học ở các nền tảng lớn như Coursera, edX, FutureLearn và XuetangX thường chỉ dao động trong khoảng 5–15%, trong đó phần lớn người học rời bỏ khóa học ngay trong vài tuần đầu tiên [2].

Đề tài của luận văn – *"Giải pháp Chẩn đoán nguy cơ không hoàn thành khoá học MOOC dựa trên hành vi học tập"* – tập trung vào bài toán dự báo sớm rủi ro bỏ học trong môi trường MOOC. Khác với cách tiếp cận phổ biến vốn đặt bài toán dưới dạng phân loại nhị phân (hoàn thành/không hoàn thành) và cố định một cửa sổ quan sát duy nhất, luận văn đề xuất một khung dự báo có tên *EarlyRisk-MOOC*, đặt bài toán dưới dạng phân loại nhãn rủi ro *có thứ tự* gồm năm mức A/B/C/D/E và đánh giá một cách hệ thống trên *nhiều cửa sổ quan sát* (W1, W2, W4 tương ứng với 1, 2 và 4 tuần đầu khóa học). Cách đặt vấn đề này cho phép lượng hóa rõ ràng sự đánh đổi giữa tính kịp thời của thời điểm cảnh báo và chất lượng của dự báo – một khía cạnh có giá trị thực tiễn cao nhưng còn ít được nghiên cứu một cách bài bản.

2. Lý do lựa chọn đề tài

Việc lựa chọn đề tài này xuất phát từ ba động cơ chính, vừa mang tính thực tiễn vừa mang tính khoa học.

Thứ nhất, về mặt thực tiễn xã hội. Bỏ học là rào cản lớn nhất ngăn MOOC phát huy hết tiềm năng phổ cập giáo dục. Mỗi một người học rời bỏ khóa học không chỉ là một cơ hội học tập bị bỏ lỡ mà còn là một tín hiệu cho thấy hệ thống đã không kịp thời

nhận diện và hỗ trợ. Nếu hệ thống có thể nhận diện sớm những người học có nguy cơ – đặc biệt trong những tuần đầu khi tín hiệu hành vi còn ít nhưng dư địa can thiệp còn nhiều – thì giảng viên và nền tảng có thể chủ động gửi nhắc nhở, điều chỉnh lộ trình hoặc cung cấp hỗ trợ phù hợp.

Thứ hai, về mặt khoa học. Mặc dù bài toán dự báo bỏ học MOOC đã được nghiên cứu hơn một thập kỷ, dù tồn tại nhiều rào cản đa dạng, qua tổng quan nghiên cứu/phân tích, ba hạn chế cốt lõi sau đây nổi lên như những điểm nghẽn lớn nhất chưa được giải quyết triệt để: (i) phần lớn công trình dùng nhãn nhị phân, gộp chung nhóm có nguy cơ với nhóm đã rời khóa, làm mất thông tin can thiệp; (ii) phần lớn công trình chỉ đo lường mô hình trên một cửa sổ quan sát cố định, không lượng hóa được đánh đổi giữa thời điểm cảnh báo và chất lượng dự báo; và (iii) các trục thiết kế phụ trợ (chiến lược điền giá trị thiếu, bộ trích xuất chuỗi, hàm mất mát) thường bị cố định thay vì được đối sánh có kiểm soát trên cùng một điều kiện. Ba hạn chế này tạo ra một khoảng trống nghiên cứu rõ ràng mà luận văn hướng tới giải quyết.

Thứ ba, về tính khả thi. Sự ra đời của bộ dữ liệu MOOCCubeX [3] – một kho dữ liệu quy mô lớn với 3,3 triệu người học và hơn 4.000 khóa học – cùng với sự sẵn có của các nền tảng xử lý dữ liệu lớn như Apache Spark [4] đã làm cho việc thực nghiệm ở quy mô hàng trăm nghìn mẫu trở nên khả thi, tạo điều kiện cho một nghiên cứu benchmark có ý nghĩa thống kê thực sự.

3. Mục tiêu nghiên cứu

Luận văn hướng đến bốn mục tiêu cụ thể, được ký hiệu lần lượt là M1–M4:

M1. Xây dựng một khung benchmark thống nhất, trong đó cùng một bộ dữ liệu (MOOCCubeX), cùng quy tắc gán nhãn 5 mức, cùng giao thức chia tập 8:1:1 và cùng hệ chỉ số đánh giá được áp dụng cho mọi cấu hình thực nghiệm.

M2. Đề xuất một kiến trúc năm tầng và tiến hành benchmark 48 cấu hình ($3\times4\times2\times2$: ba cửa sổ, bốn chiến lược điền, hai bộ trích xuất chuỗi, hai hàm mất mát).

M3. Tái hiện sáu công trình thực nghiệm tiêu biểu trên cùng một giao thức để làm chuẩn đối sánh, từ đó đánh giá và khẳng định hiệu năng của khung đề xuất.

M4. Định danh điểm vận hành cân bằng và phân tích đánh đổi chi phí–hiệu năng

theo lát cắt Pareto.

Để cụ thể hóa các mục tiêu trên, luận văn trả lời ba câu hỏi nghiên cứu (*Research Questions* – RQ):

RQ1. Cửa sổ quan sát (W1/W2/W4) ảnh hưởng như thế nào đến chất lượng dự báo, và có tồn tại một điểm vận hành cân bằng giữa thời điểm cảnh báo, hiệu năng và chi phí hay không?

RQ2. Trong các trục thiết kế phụ trợ, chiến lược điền giá trị thiếu nào cho hiệu năng tốt nhất trong bối cảnh cửa sổ thời gian sớm?

RQ3. Khung đề xuất có cải thiện đáng kể khả năng phát hiện nhóm người học cần can thiệp (lớp D) so với các baseline hay không?

4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu là người học trong các khóa học MOOC có nhật ký tương tác theo thời gian, cụ thể là những người học có tương tác thực sự trong giai đoạn đầu khóa học (4 tuần đầu).

Phạm vi nghiên cứu được giới hạn như sau. Về dữ liệu, luận văn sử dụng bộ MOOCCubeX, lọc ra cohort gồm 100.409 cặp người học–khóa học có hoạt động đạt ngưỡng tối thiểu. Về bài toán, luận văn tập trung vào dự báo rủi ro (*risk prediction*) – nghĩa là ước lượng xác suất người học rơi vào từng mức rủi ro – mà không bao gồm suy luận nhân quả hay đánh giá hiệu ứng của chính sách can thiệp sau dự báo. Về mô hình, luận văn giới hạn ở các họ phương pháp học máy truyền thống và học sâu chuỗi thời gian; các mô hình ngôn ngữ lớn và mô hình đồ thị quy mô lớn nằm ngoài phạm vi đóng góp chính.

5. Phương pháp nghiên cứu

Luận văn kết hợp phương pháp nghiên cứu lý thuyết và thực nghiệm. Về lý thuyết, luận văn tiến hành khảo sát có hệ thống các công trình liên quan, phân loại theo các họ phương pháp và tổng hợp khoảng trống nghiên cứu. Về thực nghiệm, luận văn áp dụng phương pháp *benchmark có kiểm soát*: cố định mọi yếu tố ngoài biến thí nghiệm

(cohort, nhãn, giao thức chia tập, phần cứng) để bảo đảm các so sánh là công bằng và có ý nghĩa thống kê. Hạ tầng xử lý dữ liệu (ETL) sử dụng Apache Spark; phần huấn luyện và đánh giá mô hình sử dụng các thư viện `pandas`, `scikit-learn` và `PyTorch` trong cùng một môi trường tính toán.

6. Ý nghĩa thực tiễn của đề tài

Kết quả của luận văn có ba ý nghĩa thực tiễn rõ rệt. Thứ nhất, việc đặt bài toán dưới dạng nhãn rủi ro có thứ tự cung cấp cho người vận hành hệ thống một ngữ nghĩa chi tiết hơn nhãn nhị phân, cho phép xếp hạng ưu tiên can thiệp. Thứ hai, phân tích đa cửa sổ cung cấp bằng chứng định lượng giúp người vận hành lựa chọn thời điểm cảnh báo phù hợp với ràng buộc về tài nguyên. Thứ ba, việc thiết lập một mặt bằng đối sánh chung cho các họ phương pháp tạo ra một tham chiếu hữu ích cho các nghiên cứu tiếp theo trong lĩnh vực.

7. Đóng góp chính của luận văn

Đóng góp chính của luận văn nằm ở việc đưa ra một *quan điểm thiết kế* khác biệt cho bài toán dự báo bỏ học MOOC: thay vì tìm mô hình tốt nhất ở một điểm vận hành duy nhất, luận văn đối sánh có hệ thống đánh đổi giữa thời điểm cảnh báo, chất lượng dự báo và chi phí triển khai trên cùng một mặt bằng thực nghiệm. Quan điểm này được hiện thực hóa qua bốn đóng góp cụ thể:

- *Thứ nhất*, khác với phần lớn các công trình trước đó cố định một cửa sổ quan sát duy nhất, khung đề xuất buộc mọi mô hình phải đi qua ba mức W1/W2/W4 trên cùng cohort và cùng quy tắc nhãn, khắc phục trực tiếp khoảng trống về phân tích đa cửa sổ.
- *Thứ hai*, khung tái hiện sáu baseline trên cùng cohort 100.409 cặp, cùng nhãn năm mức, cùng split 8:1:1, cùng phần cứng, tạo ra phép so sánh có ý nghĩa thống kê thực sự.
- *Thứ ba*, về hiệu suất, cấu hình W2 + KNN + BiLSTM + cb_focal đạt Macro-F1 = 0,9835, dẫn đầu ở cả ba cửa sổ W1/W2/W4, giữ 99,1% chất lượng của W4 trong khi giảm 29,2% thời gian chạy và vượt baseline tốt nhất 13,9% Macro-F1

tại W2.

- *Thứ tư*, về phương pháp luận, tại cả ba cửa sổ quan sát, cấu hình tốt nhất trong số 48 cấu hình nội tại đều dùng phép điền khuyết KNN cục bộ, cho thấy trong thiết lập cửa sổ quan sát ngắn, thông tin lân cận cục bộ trong không gian đặc trưng đã đủ để khôi phục giá trị thiếu mà không cần đến chi phí dựng đồ thị tương đồng và huấn luyện bộ điền khuyết GNN (kèm nhiều siêu tham số như τ, top-k, số epoch). Việc xác lập một thứ hạng đầy đủ giữa bốn chiến lược điền khuyết trên toàn bộ 48 cấu hình cần một phân tích tổng hợp theo trục thiết kế, được đề xuất là hướng bổ sung trực tiếp.

8. Bố cục của luận văn

Luận văn được tổ chức thành năm chương. **Chương 1** (chương này) trình bày lý do chọn đề tài, mục tiêu, đối tượng và phạm vi, phương pháp nghiên cứu, ý nghĩa thực tiễn và bố cục của luận văn. **Chương 2** tổng quan về đề tài: khảo sát các công trình liên quan theo các họ phương pháp, phân tích hiện trạng và tổng hợp khoảng trống nghiên cứu. **Chương 3** trình bày phương pháp thực hiện đề tài: cơ sở lý thuyết của các thành phần kỹ thuật, phát biểu hình thức bài toán và kiến trúc năm tầng của khung EarlyRisk-MOOC. **Chương 4** báo cáo kết quả thực nghiệm và phân tích: thiết lập thực nghiệm, kết quả đối sánh với các baseline, thực nghiệm nội tại và thảo luận. **Chương 5** (Kết luận và kiến nghị) tổng kết các phát hiện mới và đề xuất hướng nghiên cứu tiếp theo.

CHƯƠNG 2. TỔNG QUAN VỀ ĐỀ TÀI

Chương này phân tích và đánh giá các vấn đề liên quan trực tiếp đến đề tài: bối cảnh bài toán dự báo bỏ học MOOC, các họ phương pháp đã được đề xuất, nội dung và phương pháp nghiên cứu của từng họ, và cuối cùng là tổng hợp khoảng trống nghiên cứu định hướng cho phần đóng góp của luận văn.

2.1 Bối cảnh và phát biểu vấn đề

2.1.1 Hiện tượng bỏ học trong MOOC

MOOC ra đời với kỳ vọng phổ cập giáo dục đại học, nhưng thực tế vận hành lại bộc lộ một vấn đề nan giải về khả năng duy trì người học. Theo nhận định của de Freitas và cộng sự, mặc dù MOOC mở rộng đáng kể khả năng tiếp cận, mô hình này đồng thời bộc lộ tỷ lệ duy trì và tỷ lệ hoàn thành rất thấp [1]. Khảo sát có hệ thống của Deng và cộng sự trên các trải nghiệm người học MOOC giai đoạn 2008–2021 xác nhận rằng các nền tảng lớn chỉ ghi nhận 5–15% người đăng ký hoàn thành khóa, và phần lớn rời bỏ trong vài tuần đầu [2].

Hiện tượng rời bỏ sớm này có hai hệ quả quan trọng đối với việc thiết kế hệ thống dự báo. Một mặt, nó nhấn mạnh tầm quan trọng của việc *cảnh báo sớm*: nếu phần lớn người học rời bỏ trong vài tuần đầu, thì một hệ thống chỉ có thể dự báo chính xác sau khi đã thu thập đủ dữ liệu của nhiều tuần sẽ trở nên vô dụng về mặt can thiệp. Mặt khác, nó tạo ra một bài toán dữ liệu mất cân bằng nghiêm trọng, khi nhóm người học có nguy cơ cao hoặc đã rời khóa chiếm tỷ trọng áp đảo.

2.1.2 Dự báo bỏ học trong bối cảnh phân tích học tập

Bài toán dự báo bỏ học không tồn tại đơn lẻ mà nằm trong lĩnh vực rộng hơn là *phân tích học tập* (*learning analytics*) – việc thu thập, đo lường, phân tích và báo cáo dữ liệu về người học và bối cảnh học tập nhằm hiểu và tối ưu hóa quá trình học. Trong khung này, dự báo bỏ học là một bài toán *dự báo* (predictive analytics) đóng vai trò

đầu vào cho một bài toán *quy định* (prescriptive analytics) là thiết kế can thiệp. Mối quan hệ này giải thích vì sao việc chỉ tối ưu một chỉ số phân loại đơn lẻ là chưa đủ: giá trị cuối cùng của một mô hình dự báo nằm ở chỗ nó cung cấp tín hiệu đúng lúc và đủ chi tiết để hành động. Đây là lý do luận văn nhấn mạnh đồng thời ba khía cạnh – thời điểm cảnh báo, độ chi tiết của nhãn, và chất lượng phát hiện lớp can thiệp – thay vì chỉ chạy theo một con số Accuracy đơn lẻ.

2.1.3 Vì sao cần phân biệt nhiều mức rủi ro

Cách tiếp cận truyền thống đặt bài toán dưới dạng phân loại nhị phân: người học hoặc hoàn thành, hoặc không hoàn thành. Tuy nhiên, cách gộp nhóm này che giấu một sự phân biệt có ý nghĩa can thiệp cốt lõi. Trong nhóm "không hoàn thành", cần phân biệt rõ giữa người học *đã thực sự rời khóa* (không còn khả năng can thiệp) với người học *vẫn đang hoạt động nhưng có nguy cơ cao* (vẫn còn cơ hội can thiệp). Hai nhóm này đòi hỏi chiến lược hoàn toàn khác nhau: với nhóm đầu, can thiệp gần như vô ích; với nhóm sau, một nhắc nhở kịp thời có thể làm thay đổi quỹ đạo học tập. Việc gộp chung hai nhóm dưới một nhãn "không hoàn thành" do đó làm giảm đáng kể giá trị thực tiễn của mô hình dự báo. Đây chính là động cơ cho việc đặt bài toán dưới dạng nhãn rủi ro có thứ tự nhiều mức.

Hơn nữa, một nhãn năm mức còn cho phép phân biệt giữa các mức hoàn thành tốt (A, B, C), điều có giá trị cho các bài toán liên quan như xếp hạng, cấp chứng chỉ hay phân luồng nội dung. Mặc dù luận văn tập trung vào lớp can thiệp D, việc giữ đủ năm mức bảo toàn thông tin cho các ứng dụng mở rộng về sau và phản ánh trung thực hơn phổ kết quả học tập thực tế.

2.2 Tiêu chí khảo sát tài liệu

Để bảo đảm tính khách quan và tính đại diện, tài liệu khảo sát trong luận văn được chọn theo bốn tiêu chí:

(i) liên quan trực tiếp đến dự báo bỏ học hoặc cảnh báo người học có nguy cơ trong môi trường MOOC hoặc học trực tuyến quy mô lớn;

(ii) có mô tả đủ rõ về dữ liệu, mô hình hoặc thước đo để cho phép đối sánh khoa học;

(iii) đại diện cho các họ phương pháp khác nhau;

(iv) ưu tiên các nghiên cứu gốc thay vì bản tóm lược thứ cấp.

Theo các tiêu chí trên, phần khảo sát bao gồm năm nghiên cứu tổng quan có hệ thống nền tảng [5, 6, 7, 2, 1], hai bộ dữ liệu chuẩn [3, 8], và mười sáu công trình thực nghiệm tiêu biểu từ 2014 đến 2025. Các nghiên cứu tổng quan đóng vai trò định hình bức tranh tổng thể: Dalipi và cộng sự khảo sát các kỹ thuật học máy giai đoạn 2014–2018 [5]; Prenkaj và cộng sự mở rộng đến 2020 và chỉ ra rằng phần lớn công trình tập trung vào trích xuất đặc trưng thủ công từ nhật ký nhấp chuột, so sánh các mô hình học máy truyền thống và đánh giá theo nhãn nhị phân [6]; gần đây hơn, Alghamdi và cộng sự chỉ ra ba xu hướng hiện tại của lĩnh vực gồm chuyển dịch sang học sâu cho dữ liệu chuỗi, ứng dụng meta-heuristic và tối ưu hóa siêu tham số, và tích hợp khả năng giải thích (XAI) [7].

2.2.1 Sự tiến hóa của lĩnh vực qua ba giai đoạn

Nhìn tổng thể trên trục thời gian, lĩnh vực dự báo bỏ học MOOC đã trải qua ba giai đoạn phát triển có thể nhận diện rõ. *Giai đoạn nền móng (2014–2017)* đặc trưng bởi việc áp dụng các mô hình học máy truyền thống trên đặc trưng thủ công, với đóng góp chính là chứng minh rằng dropout có thể dự báo được từ tín hiệu hành vi [9, 10, 11, 12]. *Giai đoạn học sâu (2018–2022)* chứng kiến sự chuyển dịch sang các mô hình chuỗi và kiến trúc lai, cùng với các nghiên cứu phản biện cho thấy học sâu không phải luôn vượt trội [13, 14, 15, 16]. *Giai đoạn tinh vi hóa (2023–2025)* mở rộng bài toán theo nhiều hướng đồng thời: nhãn đa mức, mô hình đồ thị, tối ưu hóa meta-heuristic và khả năng giải thích [17, 18, 19, 20, 21]. Sự tiến hóa này cho thấy một xu hướng rõ: bài toán ngày càng được đặt gần với nhu cầu thực tiễn (phân biệt mức rủi ro, cảnh báo sớm, giải thích được), và đây chính là quỹ đạo mà luận văn tiếp nối và đẩy xa thêm bằng cách hợp nhất nhiều khía cạnh vào một khung benchmark thống nhất.

Các công trình thực nghiệm được phân tích thành hai họ phương pháp lớn dưới đây, sau đó tổng hợp khoảng trống ở tiểu mục cuối.

2.2.2 Hai bộ dữ liệu chuẩn của lĩnh vực

Trước khi đi vào các họ phương pháp, cần giới thiệu hai bộ dữ liệu được sử dụng phổ biến nhất, vì lựa chọn dữ liệu ảnh hưởng trực tiếp đến khả năng đối sánh giữa các công trình.

MOOCCubeX [3] là một kho dữ liệu quy mô lớn hướng tri thức, được thiết kế cho học thích ứng trong MOOC. Bộ dữ liệu bao gồm khoảng 3,3 triệu người học, hơn 4.000 khóa học và hàng trăm triệu sự kiện hành vi, cùng với một đồ thị tri thức liên kết các khái niệm. Quy mô và độ chi tiết của MOOCCubeX khiến nó trở thành lựa chọn lý tưởng cho các nghiên cứu cần cohort lớn và tín hiệu hành vi phong phú – đây là lý do luận văn chọn MOOCCubeX làm dữ liệu chính.

OULAD (Open University Learning Analytics Dataset) [8] là bộ dữ liệu phân tích học tập của Open University, bao gồm thông tin về sinh viên, khóa học, đánh giá và nhật ký tương tác với môi trường học ảo. OULAD nhỏ hơn MOOCCubeX về quy mô nhưng có ưu điểm là cấu trúc rõ ràng và được sử dụng rộng rãi, do đó thường được dùng để kiểm chứng tính tổng quát. Tuy nhiên, OULAD không phát hành trực tiếp dưới dạng nhãn năm mức A/B/C/D/E, nên việc mở rộng luận văn sang OULAD đòi hỏi một quy tắc ánh xạ nhãn cần được kiểm chứng cẩn thận – một điểm sẽ được bàn trong phần giới hạn.

Sự khác biệt giữa hai bộ dữ liệu này cũng giải thích một phần vì sao các công trình hiện có khó đối sánh trực tiếp: chúng được đánh giá trên các dữ liệu khác nhau, với các quy tắc nhãn và giao thức chia tập khác nhau. Đây chính là một trong những động cơ thúc đẩy việc xây dựng một khung benchmark thống nhất.

2.3 Họ phương pháp 1: Học máy truyền thống và tối ưu hóa

2.3.1 Các mô hình nền móng

Hướng tiếp cận sớm nhất, đại diện bởi Kloft và cộng sự năm 2014, sử dụng SVM tuyến tính trên các đặc trưng thủ công trích từ nhật ký nhấp chuột theo tuần [9]. Cùng năm, Taylor và cộng sự đề xuất hồi quy logistic với bộ đặc trưng tương tự để dự báo hiện tượng "ngừng học" (*stopout*) [10]. Mặc dù đơn giản, các công trình này đặt nền móng quan trọng cho việc xem dropout là một bài toán có thể dự báo từ tín hiệu hành

vi – một tiền đề mà toàn bộ lĩnh vực về sau dựa vào.

Một phát hiện đáng chú ý đến từ Alamri và cộng sự năm 2019: ngay cả khi chỉ dùng hai đặc trưng dễ thu thập trong tuần đầu, các mô hình cây quyết định tăng cường như RF, AdaBoost, GradientBoosting hay XGBoost vẫn đạt độ chính xác 82–94% trên 21 đợt mở của 5 khóa FutureLearn [22]. Kết quả này hàm ý rằng một mô hình cảnh báo rất sớm có thể rất nhẹ về mặt tính toán – một quan sát có ý nghĩa lớn đối với việc thiết kế hệ thống thực tế. Vitiello và cộng sự bổ sung bằng chứng cho thấy các đặc trưng phản ánh mức độ tham gia tích cực mang tín hiệu dự báo mạnh [23].

2.3.2 Tích hợp khả năng giải thích

Một biến thể gần đây của họ này tích hợp các công cụ giải thích nhằm tăng độ tin cậy và khả năng thuyết phục người dùng. Nagrecha và cộng sự xây dựng một pipeline có thể diễn giải nhằm thuyết phục giảng viên về kết quả dự báo [24]; Dass và cộng sự kết hợp RF với SHAP, đạt độ chính xác khoảng 87,5% trên khóa học tự định nhịp (*self-paced*) [25]; Bettahi và cộng sự đề xuất một pipeline mô-đun hóa kết hợp XGBoost với SHAP và LIME [21]. Tuy nhiên, hướng tích hợp giải thích này nằm ngoài phạm vi đóng góp chính của luận văn và chỉ được nhắc đến như một hướng đối sánh.

2.3.3 Tối ưu hóa lựa chọn đặc trưng và siêu tham số

Song song với việc cải tiến mô hình, một nhánh quan trọng tập trung vào tối ưu hóa không gian tìm kiếm. Psathas và cộng sự năm 2021 sử dụng Grid Search và Bayesian Optimization để tinh chỉnh nhiều bộ phân loại trên dữ liệu MOOC smart-city [26]. Đại diện hiện đại nhất của nhánh này là Aouarib và cộng sự năm 2025: kết hợp giải thuật di truyền (GA) để đồng thời chọn đặc trưng và siêu tham số cho XGBoost trên bộ dữ liệu OULAD, đánh giá tại tuần 5/15/25/35 và báo cáo cải thiện nhất quán so với LR, MLP, DT, SVM, RF và LSTM [19]. Hướng tối ưu hóa cho thấy rằng học máy truyền thống vẫn còn nhiều dư địa cải thiện thông qua thiết kế tốt hơn của không gian tìm kiếm, thay vì phụ thuộc hoàn toàn vào năng lực biểu diễn của mô hình sâu.

2.3.4 Phân tích chi tiết phương pháp luận của họ thứ nhất

Để hiểu rõ vì sao các mô hình họ này có một trần hiệu năng nhất định, cần phân tích sâu hơn về phương pháp luận chung của chúng. Điểm chung xuyên suốt là quy trình hai bước: trước hết, dữ liệu chuỗi hành vi thô được *tổng hợp* thành một vector đặc trưng cố định chiều (ví dụ tổng số lần xem video trong toàn bộ cửa sổ, trung bình điểm bài tập, độ lệch chuẩn của thời gian học); sau đó, một bộ phân loại dạng bảng được huấn luyện trên vector này. Bước tổng hợp, dù làm cho bài toán trở nên đơn giản và nhanh, lại là một "nút thắt thông tin": nó làm phẳng chiều thời gian, xóa bỏ thông tin về *trình tự* và *động học* của hành vi. Hai người học có cùng tổng số giờ học nhưng một người tăng dần và một người giảm dần sẽ có cùng vector đặc trưng tổng hợp, dù quỹ đạo rủi ro của họ trái ngược nhau.

Đây chính là lý do sâu xa giải thích vì sao, như sẽ thấy trong kết quả thực nghiệm, các mô hình họ này gần như không cải thiện khi cửa sổ quan sát kéo dài: thông tin bổ sung của các tuần sau bị nén lại trong cùng một phép tổng hợp và không được khai thác như một chuỗi. Quan sát này không phủ nhận giá trị của họ phương pháp truyền thống – chúng vẫn vượt trội về tốc độ và khả năng giải thích – mà chỉ định vị rõ ranh giới năng lực của chúng, từ đó biện minh cho sự cần thiết của các mô hình chuỗi thời gian khi mục tiêu là khai thác động học theo tuần.

2.4 Họ phương pháp 2: Học sâu và tiếp cận dựa trên đồ thị

2.4.1 Mô hình chuỗi thời gian

Họ phương pháp thứ hai chuyển trọng tâm từ đặc trưng thủ công sang mô hình hóa trực tiếp chuỗi hành vi theo tuần. Fei và Yeung năm 2015 so sánh ba kiến trúc chuỗi – IOHMM, RNN và LSTM – trên dữ liệu Coursera và edX, trong đó LSTM đạt hiệu năng cao nhất [11]. Đây là một trong những công trình đầu tiên khẳng định giá trị của mô hình tuần tự trong bài toán này. Whitehill và cộng sự đào sâu phân tích các đặc trưng thời gian và xác nhận rằng tín hiệu hành vi theo tuần là một tín hiệu dự báo mạnh [12]. Xing và Du năm 2019 đặt trọng tâm vào việc ước lượng xác suất bỏ học cá nhân hóa bằng mạng nơ-ron sâu, hướng tới mục tiêu can thiệp cá nhân hóa [13].

Các kiến trúc lai sau đó kết hợp nhiều thành phần để tăng năng lực biểu diễn.

Mubarak và cộng sự đề xuất mô hình CNN + LSTM trên ma trận tương quan 30 ngày, đồng thời tích hợp cơ chế xử lý mất cân bằng vào hàm mất mát [14]; Fu và cộng sự đề xuất CLSA (CNN + LSTM + Attention) với hiệu năng cao trên bộ KDD Cup 2015 [15].

2.4.2 Một kết luận cảnh báo: học sâu không phải lúc nào cũng vượt trội

Một đóng góp có tính phản biện quan trọng đến từ Basnet và cộng sự năm 2022. Thông qua đối sánh có hệ thống giữa học máy truyền thống và học sâu trên cùng dữ liệu, nhóm tác giả chỉ ra rằng học máy trong nhiều trường hợp có thể ngang bằng hoặc thậm chí vượt học sâu [16]. Kết luận này nhấn mạnh rằng việc lựa chọn mô hình cần dựa trên bằng chứng thực nghiệm trên cùng một giao thức, thay vì giả định mặc nhiên rằng mô hình phức tạp hơn sẽ tốt hơn – một quan điểm mà luận văn này kế thừa và củng cố. Yu và cộng sự mở rộng hướng học sâu bằng kỹ thuật meta-transfer learning giữa các MOOC khác chủ đề, cho thấy khả năng chuyển giao tri thức giữa các khóa học [27].

2.4.3 Mở rộng sang nhãn đa mức và mô hình đồ thị

Nhánh phát triển mới và quan trọng nhất đối với luận văn này là việc mở rộng bài toán từ nhãn nhị phân sang nhãn đa mức, đôi khi kết hợp với mô hình đồ thị để khai thác quan hệ giữa người học. Martins và cộng sự năm 2023 dự báo ba mức graduate/enrolled/dropout trong bối cảnh giáo dục đại học [17]; Junejo và cộng sự năm 2025 đề xuất mạng nơ-ron cho nhãn bốn mức trên OULAD, đánh giá tại các mốc 5%, 10%, 20% và 100% chiều dài khóa học [18]; Setiawan và cộng sự tổng quan có hệ thống về dự báo đa lớp dưới điều kiện mất cân bằng, đồng thời xác nhận rằng các nghiên cứu dự báo đa lớp "vẫn còn tương đối hiếm" [28].

Trong số các công trình sử dụng nhãn đa mức, Nguyen và cộng sự là một trong số hiếm hoi đặt bài toán ở năm mức A/B/C/D/E trên MOOCCubeX, kết hợp GCN adversarial với GRU, và báo cáo kết quả mạnh ($F1_D = 0{,}92$, độ chính xác $= 0{,}95$) [20]. Đây là công trình gần nhất về mặt thiết kế bài toán với luận văn hiện tại. Tuy vậy, công trình này còn hai hạn chế đáng chú ý so với hướng tiếp cận của luận văn: (i) chỉ đánh giá tại một cửa sổ cố định (4 tuần), không phân tích đánh đổi giữa thời điểm cảnh báo và chất lượng dự báo; và (ii) chi phí dựng đồ thị có thể đạt $O(n^2)$, gây khó

khăn khi mở rộng quy mô. Ở một hướng liên quan, Schwerter và cộng sự đánh giá khả năng tổng quát của các mô hình dự báo dựa trên dấu vết học tập số (dùng Elastic Net, Random Forest và XGBoost) khi chuyển giữa các khóa học và cơ sở đào tạo, và ghi nhận hiệu năng cùng độ hiệu chỉnh xác suất có thể suy giảm trong bối cảnh mới – một cảnh báo về phương pháp luận đáng lưu ý cho mọi mô hình dự báo bỏ học, kể cả những mô hình không dựa trên quan hệ đồ thị [29]. Chính những hạn chế và cảnh báo này tạo ra không gian mà EarlyRisk-MOOC hướng tới lấp đầy.

2.4.4 Phân tích chi tiết phương pháp luận của họ thứ hai

Họ phương pháp học sâu chia sẻ một triết lý đối lập với họ thứ nhất: thay vì tổng hợp chuỗi rồi phân loại, chúng giữ nguyên cấu trúc chuỗi và để mô hình tự học cách trích xuất đặc trưng thời gian. Tuy nhiên, trong nội bộ họ này cũng có sự phân hóa đáng kể về mức độ phù hợp giữa kiến trúc và dữ liệu.

Các mô hình hồi quy thuần (RNN, LSTM, BiLSTM, GRU) xử lý chuỗi một cách tự nhiên và là lựa chọn phù hợp nhất cho dữ liệu hành vi tuần. Các mô hình lai CNN + LSTM [14, 15] bổ sung khả năng trích xuất đặc trưng cục bộ qua tích chập trước khi đưa vào lớp hồi quy; cách tiếp cận này hiệu quả khi dữ liệu có cấu trúc không gian (ví dụ ma trận tương quan ngày-hành động), nhưng độ phức tạp bổ sung không phải lúc nào cũng được biện minh. Ở thái cực khác, một MLP làm phẳng chuỗi [13] – dù vẫn là mô hình "sâu" – thực chất đánh mất cấu trúc tuần tự ngay từ đầu vào, do đó không tận dụng được lợi thế của học sâu trên dữ liệu chuỗi. Sự phân hóa này củng cố một nguyên tắc thiết kế quan trọng: hiệu năng không đến từ "độ sâu" của mô hình mà từ *sự phù hợp* giữa kiến trúc và cấu trúc dữ liệu.

Về nhánh đồ thị, sức mạnh của các mô hình GCN nằm ở khả năng khai thác quan hệ giữa người học – ví dụ những người học cùng khóa hoặc có hành vi tương tự có thể cung cấp thông tin bổ sung cho nhau. Tuy nhiên, sức mạnh này đi kèm hai cái giá cụ thể của phương pháp đồ thị: chi phí dựng đồ thị $O(n^2)$, và sự phụ thuộc vào chất lượng của đồ thị được dựng – vốn có thể suy yếu khi quan hệ toàn cục giữa người học thay đổi giữa các khóa hoặc cơ sở đào tạo. Ở một bình diện rộng hơn, Schwerter và cộng sự cho thấy ngay cả các mô hình dự báo dựa trên dấu vết học tập số không dùng quan hệ đồ thị (Elastic Net, Random Forest, XGBoost) cũng có thể suy giảm hiệu năng và độ hiệu chỉnh xác suất khi chuyển giữa các khóa học hoặc cơ sở đào tạo [29], cho thấy rủi

ro tổng quát ngoài phân phối huấn luyện là vấn đề chung của bài toán dự báo bỏ học, không riêng gì các mô hình đồ thị. Luận văn này đặt giả thuyết rằng trong bối cảnh cửa sổ thời gian sớm, một chiến lược điền giá trị thiếu cục bộ và nhẹ (KNN) có thể đạt hiệu năng tương đương hoặc tốt hơn các phương pháp đồ thị toàn cục mà không phải trả chi phí dựng đồ thị nêu trên – giả thuyết sẽ được kiểm chứng trong Chương 4.

2.5 Phân tích hiện trạng và khoảng trống nghiên cứu

Bảng 2.1 tổng hợp 19 công trình tiêu biểu theo một bộ tiêu chí thống nhất gồm: nhãn sử dụng, phương pháp, dữ liệu, hiệu năng báo cáo, cửa sổ quan sát, ưu điểm và hạn chế.

Bảng 2.1. Tổng hợp 19 công trình tiêu biểu về dự báo bỏ học theo bộ tiêu chí thống nhất

Công trình	Nhãn	Phương pháp	Dữ liệu / Hiệu năng	Cửa sổ
Kloft 2014 [9]	Nhị phân	SVM, đặc trưng thủ công	MOOC tự thu thập; AUC theo tuần	Nhiều tuần
Taylor 2014 [10]	Nhị phân	Logistic Regression	MITx 6.002x	Tuần đầu
Fei & Yeung 2015 [11]	Nhị phân	IOHMM, RNN, LSTM	Coursera + edX; LSTM tốt nhất	Chuỗi tuần
Whitehill 2017 [12]	Nhị phân	LR + đặc trưng thời gian	HarvardX, MITx; AUC $\approx$ 0,90	Nhiều tuần
Nagrecha 2017 [24]	Nhị phân	Pipeline diễn giải	MITx, HarvardX	1 cửa sổ
Vitiello 2018 [23]	Nhị phân	LR, RF, AdaBoost	MOOC tự thu thập	Nhiều tuần
Alamri 2019 [22]	Nhị phân	RF, AdaBoost, GB, XGBoost	FutureLearn; Acc. 82–94%	Tuần 1
Xing & Du 2019 [13]	Nhị phân	Deep MLP cá nhân hóa	2 nguồn MOOC	1 cửa sổ
Mubarak 2021 [14]	Nhị phân	CNN + LSTM (ma trận 30 ngày)	KDD Cup 2015; AUC $>$ 0,90	Tuần đầu
Fu 2021 [15]	Nhị phân	CLSA (CNN+LSTM+Att.)	KDD Cup 2015; AUC cao	1 cửa sổ
Dass 2021 [25]	Nhị phân	RF + tiến độ + SHAP	Open edX; Acc. 87,5%	Theo ngày
Psathas 2021 [26]	Nhị phân	Nhiều bộ PL + tối ưu siêu TS	MOOC smart-city; Acc. $\approx$ 88%	Sớm
Basnet 2022 [16]	Nhị phân	Đối sánh ML vs. DL	XuetangX, KDD; Acc. 84–88%	1 cửa sổ
Yu 2022 [27]	Nhị phân	BiLSTM + meta-transfer	Nhiều MOOC; trans-domain	1 cửa sổ
Martins 2023 [17]	3 mức	RF + xử lý mất cân bằng	ĐH Bồ Đào Nha	Phase đầu
Junejo 2025 [18]	4 mức	Mạng nơ-ron	OULAD; Acc. $>$ 93% tại mốc cuối	5/10/20/100%
Aouarib 2025 [19]	Nhị phân	GA + XGBoost	OULAD; Acc. 81–98%	4 cửa sổ
Bettahi 2025 [21]	Nhị phân	9 mô hình + SHAP, LIME	17.883 SV; AUC 0,993	1 cửa sổ
Nguyen 2025 [20]	5 mức	GCN adversarial + GRU	MOOCCubeX; $F1_D = 0{,}92$	4 tuần

Từ Bảng 2.1 có thể rút ra ba khoảng trống lớn, xác định không gian đóng góp cho luận văn:

Khoảng trống thứ nhất – ngữ nghĩa rủi ro nhiều mức. Khoảng 16 trong 19 công trình dùng nhãn nhị phân, và chỉ duy nhất một công trình (Nguyen và cộng sự) dùng nhãn 5 mức A/B/C/D/E trên MOOCCubeX. Nhãn nhị phân gộp chung nhóm "đang hoạt động nhưng rủi ro cao" với nhóm "đã rời khóa", mặc dù hai nhóm này có ý nghĩa can thiệp hoàn toàn khác nhau.

Khoảng trống thứ hai – phân tích đa cửa sổ. Chỉ khoảng 4 trong 19 công trình đánh giá tại nhiều cửa sổ quan sát; phần lớn còn lại cố định một thời điểm duy nhất. Điều này dẫn đến thiếu bằng chứng định lượng cho đánh đổi giữa thời điểm cảnh báo sớm và chất lượng dự báo.

Khoảng trống thứ ba – thiếu khung đối sánh thống nhất. Trong toàn bộ 19 công trình, các trục thiết kế phụ trợ (điền giá trị thiếu, bộ trích xuất chuỗi, hàm mất mát) thường được cố định khi báo cáo kết quả, ít khi được benchmark song song có kiểm soát. Cả Dalipi và cộng sự lẫn Prenkaj và cộng sự đều nhấn mạnh khoảng trống này [5, 6].

Tổng hợp cả ba khoảng trống nêu trên chính là bối cảnh trực tiếp cho thiết kế của khung EarlyRisk-MOOC được trình bày trong Chương 3.

2.6 Định vị thiết kế của khung đề xuất

Để làm rõ đóng góp về mặt thiết kế, Bảng 2.2 định vị EarlyRisk-MOOC so với một số công trình tiêu biểu theo các tiêu chí liên quan đến cảnh báo sớm. Đây là so sánh định tính ở khía cạnh thiết kế; phần benchmark định lượng sẽ được trình bày trong Chương 4.

Bảng 2.2. Định vị thiết kế của EarlyRisk-MOOC so với các công trình khảo sát (✓: có; △: một phần; ×: không)

Công trình	Cảnh báo sớm	Nhãn đa mức	Trục TK là biến TN	Đa cửa sổ	Báo cáo chi phí
Fei & Yeung 2015	✓	×	×	✓	×
Alamri 2019	✓	×	×	×	△
Xing & Du 2019	✓	×	×	△	×
Mubarak 2021	✓	×	△	×	×
Dass 2021	✓	×	×	✓	△
Basnet 2022	△	×	×	×	×
Junejo 2025	✓	✓ (4 mức)	×	✓	△
Aouarib 2025	✓	×	×	✓	×
Nguyen 2025	✓	✓ (5 mức)	✓	×	✓
EarlyRisk-MOOC	✓	✓ (5 mức)	✓	✓	✓

Như Bảng 2.2 thể hiện, EarlyRisk-MOOC là khung duy nhất trong số các công trình khảo sát đáp ứng đồng thời cả năm tiêu chí: cảnh báo sớm trên nhiều cửa sổ, nhãn đa mức, coi các trục thiết kế là biến thí nghiệm, phân tích đa cửa sổ và báo cáo chi phí triển khai. Sự "cân bằng" này – thay vì tối ưu một khía cạnh đơn lẻ – chính là đặc trưng thiết kế cốt lõi của khung đề xuất.

2.7 Kết luận chương

Chương này đã khảo sát có hệ thống 19 công trình tiêu biểu thuộc hai họ phương pháp chính, phân tích hiện trạng và tổng hợp ba khoảng trống nghiên cứu: thiếu ngữ nghĩa rủi ro nhiều mức, thiếu phân tích đa cửa sổ, và thiếu khung đối sánh thống nhất. Ba khoảng trống này định hướng trực tiếp cho thiết kế của khung EarlyRisk-MOOC. Chương tiếp theo trình bày cơ sở lý thuyết và kiến trúc chi tiết của khung đề xuất.

CHƯƠNG 3. PHƯƠNG PHÁP THỰC HIỆN ĐỀ TÀI

Chương này trình bày cơ sở lý thuyết của các thành phần kỹ thuật được sử dụng, phát biểu hình thức bài toán dự báo rủi ro có thứ tự, và mô tả chi tiết kiến trúc năm tầng của khung EarlyRisk-MOOC.

3.1 Cơ sở lý thuyết

3.1.1 Học có giám sát và bài toán phân loại

Bài toán dự báo rủi ro bỏ học thuộc phạm trù *học có giám sát* (*supervised learning*): từ một tập dữ liệu huấn luyện gồm các cặp (đầu vào, nhãn), mô hình học một ánh xạ từ không gian đầu vào sang không gian nhãn sao cho tổng quát hóa tốt cho dữ liệu mới. Trong phân loại, không gian nhãn là rời rạc. Mục tiêu học được hình thức hóa như việc tìm tham số θ tối thiểu hóa một hàm mất mát kỳ vọng trên phân phối dữ liệu, được xấp xỉ bằng trung bình thực nghiệm trên tập huấn luyện. Vì phân phối thực không quan sát được trực tiếp, chất lượng của mô hình phải được đánh giá trên một tập kiểm tra tách biệt, không được dùng trong quá trình huấn luyện – nguyên tắc cơ bản này chính là cơ sở của giao thức chia tập 8:1:1 trong luận văn.

Sự thành công của một mô hình học có giám sát phụ thuộc vào ba yếu tố: chất lượng và lượng dữ liệu, sự phù hợp giữa lớp mô hình và cấu trúc bài toán, và chất lượng của quá trình tối ưu. Luận văn tác động vào cả ba: sử dụng cohort lớn và được lọc cẩn thận (yếu tố dữ liệu), lựa chọn mô hình chuỗi thời gian phù hợp với dữ liệu tuần tự (yếu tố mô hình), và áp dụng quy trình huấn luyện có chính quy hóa và dừng sớm (yếu tố tối ưu).

3.1.2 Bài toán phân loại có thứ tự

Phân loại có thứ tự (*ordinal classification*) là một biến thể của bài toán phân loại trong đó các nhãn có một quan hệ thứ tự tự nhiên. Khác với phân loại danh định (*nominal*) – nơi mọi sai lệch giữa các lớp đều bị phạt như nhau – phân loại có thứ tự coi việc dự báo sai một bậc (ví dụ dự báo lớp C khi nhãn thật là B) là ít nghiêm trọng hơn sai nhiều bậc (dự báo lớp E khi nhãn thật là B). Trong bài toán dự báo rủi ro bỏ học, năm mức $\mathrm{A} \succ \mathrm{B} \succ \mathrm{C} \succ \mathrm{D} \succ \mathrm{E}$ mang một thứ tự rủi ro rõ ràng, do đó việc khai thác cấu trúc thứ tự này thông qua một thành phần mất mát chuyên biệt là một lựa chọn thiết kế hợp lý.

3.1.3 Mạng nơ-ron hồi quy và LSTM

Mạng nơ-ron hồi quy (RNN) là một họ kiến trúc được thiết kế để xử lý dữ liệu chuỗi, trong đó trạng thái ẩn tại mỗi bước thời gian phụ thuộc vào đầu vào hiện tại và trạng thái ẩn của bước trước. Một cách hình thức, với chuỗi đầu vào $\mathbf{x}_1, \ldots, \mathbf{x}_T$, RNN cập nhật trạng thái ẩn theo $\mathbf{h}_t = \tanh(W\mathbf{x}_t + U\mathbf{h}_{t-1} + b)$. Tính chất hồi quy này cho phép RNN, về mặt lý thuyết, ghi nhớ thông tin từ toàn bộ lịch sử chuỗi. Tuy nhiên, RNN thuần gặp khó khăn nghiêm trọng với hiện tượng *tiêu biến gradient* (*vanishing gradient*) hoặc *bùng nổ gradient* (*exploding gradient*) khi xử lý các chuỗi dài. Nguyên nhân nằm ở chỗ trong quá trình lan truyền ngược qua thời gian, gradient được nhân liên tiếp với ma trận trọng số qua nhiều bước; nếu các giá trị riêng của ma trận này nhỏ hơn 1, gradient suy giảm theo hàm mũ và tín hiệu học từ các bước xa biến mất, khiến mạng khó học được các phụ thuộc dài hạn.

Mạng *Long Short-Term Memory* (LSTM), do Hochreiter và Schmidhuber đề xuất, khắc phục hạn chế này thông qua cơ chế cổng. Mỗi tế bào LSTM duy trì một trạng thái tế bào c_t – một "băng chuyền" thông tin chạy xuyên suốt chuỗi với rất ít biến đổi tuyến tính – và sử dụng ba cổng để điều tiết luồng thông tin: cổng quên f_t quyết định thông tin nào trong trạng thái tế bào cần loại bỏ, cổng vào i_t quyết định thông tin mới nào cần ghi vào, và cổng ra o_t quyết định phần nào của trạng thái tế bào được xuất ra.

Các phương trình của một tế bào LSTM tại bước thời gian t được biểu diễn như sau:

$$f_t = \sigma(W_f \mathbf{x}_t + U_f \mathbf{h}_{t-1} + b_f), \tag{3.1}$$

$$i_t = \sigma(W_i \mathbf{x}_t + U_i \mathbf{h}_{t-1} + b_i), \tag{3.2}$$

$$\tilde{c}_t = \tanh(W_c \mathbf{x}_t + U_c \mathbf{h}_{t-1} + b_c), \tag{3.3}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \tag{3.4}$$

$$o_t = \sigma(W_o \mathbf{x}_t + U_o \mathbf{h}_{t-1} + b_o), \tag{3.5}$$

$$\mathbf{h}_t = o_t \odot \tanh(c_t), \tag{3.6}$$

trong đó σ là hàm sigmoid, $\odot$ là phép nhân phần tử, $W_\bullet$, $U_\bullet$ là các ma trận trọng số và $b_\bullet$ là các vector độ chệch. Cơ chế cổng quên cho phép mạng chủ động giữ lại hoặc loại bỏ thông tin trong trạng thái tế bào, nhờ đó học được các phụ thuộc dài hạn mà RNN thuần không làm được.

3.1.4 BiLSTM: LSTM hai chiều

Một hạn chế của LSTM một chiều là tại mỗi bước thời gian, mô hình chỉ có thể truy cập thông tin từ quá khứ (các bước trước đó). Mạng *Bidirectional LSTM* (BiLSTM) khắc phục hạn chế này bằng cách xử lý chuỗi đầu vào theo cả hai chiều: một LSTM thuận xử lý chuỗi từ bước đầu đến bước cuối, và một LSTM ngược xử lý chuỗi theo chiều ngược lại. Tại mỗi bước thời gian t, trạng thái ẩn của hai chiều được nối lại:

$$\mathbf{h}_t = \left[\overrightarrow{\mathbf{h}}_t \, ; \, \overleftarrow{\mathbf{h}}_t \right], \tag{3.7}$$

trong đó $\overrightarrow{\mathbf{h}}_t$ là trạng thái ẩn của LSTM thuận và $\overleftarrow{\mathbf{h}}_t$ là trạng thái ẩn của LSTM ngược. Cấu trúc hai chiều này cung cấp cho mô hình một ngữ cảnh phong phú hơn, kết hợp cả thông tin từ quá khứ và tương lai trong chuỗi, do đó nắm bắt được các phụ thuộc thời gian mà mô hình một chiều bỏ lỡ.

Trong bối cảnh bài toán dự báo bỏ học, mỗi người học được biểu diễn bởi một chuỗi vector hành vi theo tuần. Do toàn bộ chuỗi của cửa sổ quan sát được cung cấp đồng thời tại thời điểm dự báo (chế độ ngoại tuyến), việc cho phép mô hình "nhìn" cả hai chiều của chuỗi là hợp lý và mang lại lợi thế biểu diễn. Đây là lý do luận văn chọn BiLSTM làm bộ trích xuất chuỗi chủ đạo. Nhiều nghiên cứu thực nghiệm trong các lĩnh vực khác nhau – từ xử lý ngôn ngữ tự nhiên đến dự báo chuỗi thời gian – đã

xác nhận rằng BiLSTM thường đạt hiệu năng cao hơn các biến thể một chiều khi ngữ cảnh hai phía của một bước thời gian là quan trọng.

Cần lưu ý một điểm quan trọng về tính nhân quả. Trong các ứng dụng dự báo trực tuyến thời gian thực – nơi mô hình phải dự báo tại tuần t mà chưa biết dữ liệu của tuần $t+1$ – việc dùng chiều ngược (nhìn về tương lai) sẽ vi phạm tính nhân quả. Tuy nhiên, trong thiết lập của luận văn, dự báo được thực hiện *sau* khi đã thu thập đủ dữ liệu của toàn bộ cửa sổ quan sát W; tất cả các tuần từ 1 đến W đều đã xảy ra trong quá khứ tại thời điểm dự báo. Do đó, việc BiLSTM "nhìn" từ tuần W ngược về tuần 1 không phải là nhìn về tương lai mà chỉ là đọc lại lịch sử theo chiều ngược – hoàn toàn hợp lệ. Nguyên tắc chống rò rỉ mà luận văn tuân thủ (không dùng dữ liệu của tuần sau W) bảo đảm điều này. Đây là một điểm tinh tế nhưng thiết yếu, phân biệt giữa "nhìn về tương lai" (bị cấm) và "đọc ngược lịch sử đã có" (được phép).

3.1.5 GRU và cơ chế chú ý nhẹ

Gated Recurrent Unit (GRU) là một biến thể đơn giản hóa của LSTM, hợp nhất cổng quên và cổng vào thành một cổng cập nhật duy nhất và lược bỏ trạng thái tế bào riêng biệt. Nhờ ít tham số hơn, GRU thường huấn luyện nhanh hơn LSTM trong khi vẫn giữ được khả năng mô hình hóa phụ thuộc dài hạn ở mức tương đương trên nhiều bài toán. Trong luận văn, bộ trích xuất chuỗi thứ hai – ký hiệu GRU-AttentionLite – kết hợp một lớp GRU với một cơ chế chú ý (*attention*) nhẹ, trong đó trọng số chú ý α_t tại mỗi bước thời gian được tính bằng:

$$\alpha_t = \frac{\exp(e_t)}{\sum_{\tau=1}^{W} \exp(e_\tau)}, \qquad e_t = \mathbf{v}^\top \tanh(W_a \mathbf{h}_t + b_a), \tag{3.8}$$

và biểu diễn chuỗi cuối cùng là tổng có trọng số $\mathbf{c} = \sum_t \alpha_t \mathbf{h}_t$. Cơ chế này cho phép mô hình tập trung vào các tuần mang nhiều thông tin nhất, đồng thời giữ chi phí tính toán thấp hơn BiLSTM. Việc benchmark song song hai bộ trích xuất này cho phép trả lời câu hỏi liệu năng lực biểu diễn bổ sung của BiLSTM có thực sự cần thiết hay không.

Cơ chế chú ý có một lợi ích phụ đáng giá về mặt diễn giải: các trọng số α_t cho biết mô hình "chú ý" vào tuần nào nhiều nhất khi đưa ra quyết định. Trong bối cảnh dự báo bỏ học, nếu mô hình gán trọng số cao cho tuần mà mức độ tham gia của người học sụt giảm mạnh, điều đó phù hợp với trực giác rằng sự sụt giảm này là tín hiệu cảnh báo.

Như vậy, GRU-AttentionLite không chỉ là một lựa chọn nhẹ hơn về chi phí mà còn cung cấp một cửa sổ nhìn vào lý do đằng sau dự báo – một tính chất mà BiLSTM thuần khó cung cấp trực tiếp. Đây là một sự đánh đổi thú vị giữa hiệu năng thô (nghiêng về BiLSTM) và khả năng diễn giải (nghiêng về GRU-AttentionLite), và việc benchmark cả hai cho phép người vận hành lựa chọn theo ưu tiên cụ thể của mình.

3.1.6 Chiến lược điền giá trị thiếu

Dữ liệu hành vi MOOC thường có nhiều giá trị thiếu: một người học có thể không có bất kỳ tương tác nào trong một tuần nào đó. Cách xử lý giá trị thiếu là một trục thiết kế quan trọng nhưng thường bị bỏ qua. Luận văn benchmark bốn chiến lược:

- **median** – điền bằng trung vị của từng đặc trưng, ước lượng trên tập huấn luyện. Đây là phương pháp đơn giản và nhanh nhất, dùng làm chuẩn so sánh.
- **KNN** – điền bằng trung bình của k láng giềng gần nhất trong không gian đặc trưng. Phương pháp này khai thác thông tin cục bộ: các người học có hành vi tương tự sẽ được dùng để ước lượng giá trị thiếu cho nhau. Cụ thể, với một mẫu có giá trị thiếu, thuật toán xác định k mẫu gần nhất theo một độ đo khoảng cách (thường là khoảng cách Euclid) trên các chiều có giá trị quan sát được, rồi gán giá trị thiếu bằng trung bình (hoặc trung bình có trọng số theo khoảng cách) của các láng giềng đó. Khoảng cách Euclid bình phương giữa hai mẫu **x** và **y** trên d chiều quan sát được tính bằng $\sum_{j=1}^{d}(x_j - y_j)^2$. Ưu điểm chính của KNN so với điền trung vị là nó bảo toàn được quan hệ giữa các đặc trưng và không đòi hỏi giả định về phân phối dữ liệu; nhược điểm là chi phí tính khoảng cách tăng theo số mẫu và độ nhạy với điểm ngoại lai. Một nghiên cứu đánh giá có hệ thống cho thấy k trong khoảng nhỏ (ví dụ $k = 3$) thường cho cân bằng tốt giữa sai số điền và bảo toàn cấu trúc dữ liệu. Giá trị k trong luận văn được ước lượng trên tập huấn luyện.
- **graph_only** – điền dựa trên một đồ thị quan hệ giữa người học, lan truyền thông tin qua các cạnh của đồ thị.
- **graph_adv** – biến thể nâng cao của graph_only, sử dụng cơ chế đối kháng (*adversarial*) để cải thiện chất lượng điền, tương tự cách tiếp cận của Nguyen và cộng sự [20].

Hai chiến lược dựa trên đồ thị có khả năng biểu diễn mạnh hơn nhưng phải trả giá bằng chi phí dựng đồ thị, có thể đạt $O(n^2)$ với n là số người học. Việc đối sánh bốn chiến lược này một cách có kiểm soát giúp trả lời RQ2: liệu sự phức tạp bổ sung của các phương pháp dựa trên đồ thị có thực sự mang lại lợi ích trong bối cảnh cửa sổ thời gian sớm hay không.

3.1.7 Hàm mất mát cho dữ liệu mất cân bằng

Do dữ liệu MOOC mất cân bằng lớp rõ rệt, việc sử dụng hàm mất mát cross-entropy thông thường sẽ khiến mô hình thiên lệch về phía các lớp đa số. Luận văn sử dụng hàm mất mát *Class-Balanced Focal Loss* (CB-Focal) do Cui và cộng sự đề xuất [30]. Ý tưởng cốt lõi là tái cân bằng đóng góp của mỗi lớp vào hàm mất mát theo *số mẫu hữu hiệu* (*effective number of samples*) thay vì theo số mẫu tuyệt đối, dựa trên nhận định rằng khi số mẫu tăng, thông tin bổ sung của mỗi mẫu mới giảm dần do hiện tượng chồng lấp.

Số mẫu hữu hiệu của lớp có n_y mẫu được định nghĩa là $E_{n_y} = (1 - \beta^{n_y})/(1 - \beta)$, với $\beta \in [0, 1)$ là siêu tham số. Trọng số tái cân bằng của lớp y là:

$$\alpha_y = \frac{1 - \beta}{1 - \beta^{n_y}}. \tag{3.9}$$

Khi $\beta \to 0$, không có tái cân bằng; khi $\beta \to 1$, trọng số tiệm cận tỷ lệ nghịch với tần suất lớp. Kết hợp trọng số này với thành phần điều biến focal $(1 - p_i^t)^\gamma$ (giúp tập trung vào các mẫu khó), hàm CB-Focal cho bài toán C lớp được viết:

$$\mathcal{L}_{\text{CB-Focal}} = -\frac{1 - \beta}{1 - \beta^{n_y}} \sum_{i=1}^{C} (1 - p_i^t)^\gamma \log(p_i^t), \tag{3.10}$$

trong đó p_i^t là xác suất dự báo cho lớp i và γ là tham số điều khiển mức độ tập trung vào mẫu khó. Theo khuyến nghị của Cui và cộng sự, các giá trị $\beta = 0{,}999$ và γ trong khoảng $[0{,}5; 2]$ thường cho hiệu năng tốt [30].

Để khai thác cấu trúc thứ tự của nhãn, luận văn bổ sung một thành phần mất mát thứ bậc (*ordinal*) và kết hợp tuyến tính với CB-Focal:

$$\mathcal{L} = \lambda \, \mathcal{L}_{\text{CB-Focal}} + (1 - \lambda) \, \mathcal{L}_{\text{Ord}}, \tag{3.11}$$

trong đó $\mathcal{L}_{\text{Ord}}$ phạt thêm theo khoảng cách thứ bậc giữa lớp dự báo và lớp thật, và $\lambda \in [0, 1]$ điều tiết tỷ trọng giữa hai thành phần. Biến thể chỉ dùng CB-Focal được ký hiệu `cb_focal`; biến thể kết hợp cả hai được ký hiệu `cb_focal_ordinal`. Hai biến thể này được benchmark song song.

Một cách hiểu trực quan về thành phần thứ bậc: trong bài toán năm mức A/B/C/D/E, một mô hình dự báo lớp C khi nhãn thật là B chỉ sai một bậc, trong khi dự báo lớp E khi nhãn thật là B sai ba bậc. Hàm cross-entropy thông thường phạt cả hai sai lầm như nhau, làm mất thông tin về cấu trúc thứ tự. Thành phần $\mathcal{L}_{\text{Ord}}$ khắc phục điều này bằng cách đưa khoảng cách thứ bậc vào hàm phạt, khuyến khích mô hình khi sai thì sai gần thay vì sai xa. Trong bối cảnh dự báo rủi ro, tính chất này có ý nghĩa thực tiễn: một cảnh báo lệch một mức rủi ro ít gây hại hơn nhiều so với một cảnh báo lệch hoàn toàn về phía đối lập.

3.1.8 Hàm softmax và diễn giải xác suất

Tầng đầu ra của mọi mô hình trong khung sử dụng hàm softmax để chuyển các điểm số thô (logit) thành một phân phối xác suất hợp lệ trên năm lớp:

$$\hat{p}_{i,k} = \frac{\exp(z_{i,k})}{\sum_{j=1}^{5} \exp(z_{i,j})}, \tag{3.12}$$

trong đó $z_{i,k}$ là logit của lớp k cho mẫu i. Đầu ra softmax bảo đảm $\sum_k \hat{p}_{i,k} = 1$ và mỗi $\hat{p}_{i,k} \in (0, 1)$, cho phép diễn giải như xác suất. Chính nhờ tính chất này mà các điểm rủi ro dùng để xếp hạng ưu tiên can thiệp – được định nghĩa cụ thể ở Mục 3.2 – có ý nghĩa như xác suất thực sự và nhất quán về mặt toán học. Chất lượng của ước lượng xác suất này – đo bằng AUC-OVR – do đó cũng quan trọng không kém quyết định phân loại cuối cùng.

3.1.9 Quá khớp, chính quy hóa và tính tổng quát

Một mô hình học sâu với nhiều tham số có nguy cơ *quá khớp* (*overfitting*): học thuộc lòng dữ liệu huấn luyện thay vì học các quy luật tổng quát, dẫn đến hiệu năng cao trên tập huấn luyện nhưng kém trên dữ liệu mới. Luận văn áp dụng ba kỹ thuật chính quy hóa để giảm nguy cơ này. *Dropout* ngẫu nhiên vô hiệu hóa một tỷ lệ nơ-ron trong quá trình huấn luyện, buộc mạng không phụ thuộc quá mức vào bất kỳ đặc trưng đơn lẻ

nào. *Dừng sớm* theo dõi hiệu năng trên tập kiểm định và dừng huấn luyện khi hiệu năng này ngừng cải thiện, ngăn mô hình tiếp tục tối ưu trên nhiễu của tập huấn luyện. *Chuẩn hóa đặc trưng* bảo đảm các đặc trưng ở cùng thang đo, giúp quá trình tối ưu ổn định hơn.

Cần phân biệt giữa *tổng quát trong phân phối* (dữ liệu kiểm tra cùng phân phối với huấn luyện, như trong giao thức chia tập ngẫu nhiên của luận văn) và *tổng quát ngoài phân phối* (dữ liệu từ khóa học hoặc cơ sở khác). Luận văn hiện tại đánh giá loại thứ nhất; Schwerter và cộng sự [29] cho thấy loại thứ hai khó hơn nhiều đối với các mô hình dự báo dựa trên dấu vết học tập số nói chung – kể cả các mô hình không dùng quan hệ đồ thị – khi chuyển giữa các khóa học hoặc cơ sở đào tạo. Đây là một lý do nữa để thận trọng khi diễn giải khả năng tổng quát của khung đề xuất, và là cơ sở cho hướng nghiên cứu về giao thức hold-out nghiêm ngặt hơn được đề xuất ở phần kết luận.

3.1.10 Các chỉ số đánh giá

Vì dữ liệu mất cân bằng lớp rõ rệt, luận văn báo cáo sáu nhóm chỉ số thay vì chỉ dựa vào độ chính xác. *Accuracy* được giữ làm tham chiếu quen thuộc dù ít có ý nghĩa khi lớp đa số chiếm tỷ trọng lớn. Hai chỉ số chính là:

$$\text{Macro-F1} = \frac{1}{K}\sum_{k=1}^{K} F1_k, \qquad \text{Weighted-F1} = \sum_{k=1}^{K} \omega_k F1_k, \tag{3.13}$$

trong đó K là số lớp, $F1_k$ là điểm F1 của lớp k và ω_k là trọng số theo tần suất. Macro-F1 đặc biệt quan trọng vì nó phạt nặng khi mô hình phân loại sai các lớp thiểu số. Ngoài ra, $F1_D$ và $F1_E$ được báo cáo riêng cho lớp can thiệp (D) và lớp đã rời khóa (E); AUC-OVR (*One-vs-Rest*) đo khả năng phân biệt đa lớp ở mức xác suất. Thời gian chạy được đo bằng đồng hồ bao quanh giai đoạn huấn luyện (không tính ETL), và số tham số mô hình được dùng làm chỉ báo độ phức tạp.

Để hiểu rõ ý nghĩa của các chỉ số trên, cần nhắc lại các đại lượng nền tảng từ ma trận nhầm lẫn. Với một lớp k, gọi TP_k, FP_k, FN_k lần lượt là số dự báo đúng dương, dương giả và âm giả. Khi đó:

$$\text{Precision}_k = \frac{TP_k}{TP_k + FP_k}, \quad \text{Recall}_k = \frac{TP_k}{TP_k + FN_k}, \quad F1_k = \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k}. \tag{3.14}$$

Trong bối cảnh dự báo bỏ học, Recall$_D$ – tỷ lệ phát hiện đúng nhóm rủi ro cao – có ý nghĩa thực tiễn lớn, vì bỏ sót một người học cần can thiệp (âm giả) thường tốn kém hơn một cảnh báo nhầm (dương giả). $F1_D$ tổng hợp cả hai khía cạnh này thành một chỉ số duy nhất, do đó được báo cáo riêng và dùng làm một trong hai trục của phân tích Pareto (cùng với Macro-F1) khi lựa chọn điểm vận hành. Sự khác biệt giữa Accuracy và Macro-F1 cũng đáng lưu ý: trên một bộ dữ liệu mà lớp D chiếm hơn 64%, một mô hình "ngây thơ" luôn dự báo lớp D đã có thể đạt Accuracy trên 64% mà không hề có khả năng phân biệt; trong khi đó Macro-F1 của mô hình ngây thơ này sẽ rất thấp vì các lớp còn lại đều có $F1 = 0$. Đây chính là lý do luận văn ưu tiên Macro-F1 làm chỉ số chính.

3.1.11 Về tính có ý nghĩa thống kê và khả năng tái lập

Một điểm phương pháp luận quan trọng của luận văn là bảo đảm các so sánh giữa các hệ thống có ý nghĩa thống kê. Điều này đạt được thông qua ba cơ chế. *Thứ nhất*, mọi hệ thống được đánh giá trên *cùng một cohort* 100.409 cặp, *cùng một split* 8:1:1 và *cùng một hạt giống* ngẫu nhiên 42. Nhờ đó, sự khác biệt về hiệu năng giữa các hệ thống phản ánh khác biệt thực sự về năng lực mô hình, không phải khác biệt ngẫu nhiên do dữ liệu hay cách chia tập. *Thứ hai*, quy mô cohort lớn (hàng trăm nghìn mẫu) làm giảm phương sai của các ước lượng hiệu năng, khiến các khoảng cách quan sát được (ví dụ 13,9% Macro-F1 tại W2) đủ lớn để tin cậy. *Thứ ba*, việc cố định phần cứng bảo đảm các so sánh về thời gian chạy là công bằng.

So với nhiều nghiên cứu trước vốn so sánh các mô hình được đánh giá trên các dữ liệu, giao thức và phần cứng khác nhau, cách tiếp cận này của luận văn đưa việc đối sánh lên một mức độ chặt chẽ cao hơn. Đây chính là ý nghĩa cốt lõi của cụm từ "benchmark thống nhất" trong tên khung: không chỉ chạy nhiều mô hình, mà chạy chúng trong một điều kiện được kiểm soát nghiêm ngặt để mọi khác biệt quan sát được đều có thể quy về khác biệt về thiết kế mô hình.

3.1.12 Các mô hình baseline học máy truyền thống

Để bảo đảm tính tự chứa của luận văn, mục này tóm lược ngắn gọn cơ sở của các họ mô hình baseline được tái hiện. *Cây quyết định* phân hoạch không gian đặc trưng theo các ngưỡng được chọn để tối đa hóa độ thuần khiết của các nút lá. *Rừng ngẫu nhiên*

(RF) kết hợp nhiều cây quyết định huấn luyện trên các tập con dữ liệu và đặc trưng được lấy mẫu ngẫu nhiên, sau đó tổng hợp dự báo bằng bỏ phiếu; cơ chế này giảm phương sai và chống quá khớp hiệu quả. *Gradient Boosting* và biến thể tối ưu hóa của nó là *XGBoost* xây dựng các cây tuần tự, trong đó mỗi cây mới được huấn luyện để sửa sai số phần dư của tổ hợp các cây trước; XGBoost bổ sung chính quy hóa và nhiều tối ưu hóa kỹ thuật giúp nó trở thành một trong những mô hình mạnh nhất trên dữ liệu dạng bảng. *AdaBoost* là một thuật toán boosting sớm hơn, tăng trọng số cho các mẫu bị phân loại sai ở vòng trước. Các mô hình họ cây này có chung đặc điểm: chúng hoạt động trên các đặc trưng đã được *tổng hợp* (aggregated) thành dạng bảng, do đó không khai thác trực tiếp cấu trúc tuần tự của chuỗi hành vi – một đặc điểm sẽ giải thích vì sao chúng ít hưởng lợi từ cửa sổ quan sát dài hơn, như sẽ thấy trong Chương 4.

3.1.13 Đặc điểm dữ liệu MOOC và tín hiệu hành vi theo tuần

Dữ liệu MOOC có ba đặc điểm chi phối thiết kế mô hình. *Thứ nhất, tính chuỗi thời gian.* Hành vi học tập diễn ra theo tuần, với các tín hiệu như thời lượng xem video, số lần thử bài tập thay đổi theo tiến trình khóa học; những thay đổi này (ví dụ giảm dần mức độ tham gia) thường là dấu hiệu cảnh báo sớm của việc rời bỏ. *Thứ hai, tính mất cân bằng.* Như đã phân tích, nhóm rủi ro cao và bỏ học chiếm tỷ trọng áp đảo. *Thứ ba, tính thưa và thiếu.* Nhiều người học không có tương tác trong một số tuần, tạo ra giá trị thiếu mà cách xử lý ảnh hưởng trực tiếp đến chất lượng dự báo. Ba đặc điểm này lần lượt biện minh cho ba lựa chọn thiết kế cốt lõi của khung: bộ trích xuất chuỗi thời gian (cho đặc điểm thứ nhất), hàm mất mát tái cân bằng (cho đặc điểm thứ hai), và việc benchmark các chiến lược điền giá trị thiếu (cho đặc điểm thứ ba).

3.2 Phát biểu và mô hình hóa bài toán

Khung EarlyRisk-MOOC hướng đến ba yêu cầu đồng thời: (i) phát hiện sớm, chỉ với 1, 2 hoặc 4 tuần đầu; (ii) hiệu năng dự báo cao, đặc biệt ở lớp can thiệp; và (iii) chi phí vận hành chấp nhận được.

Cửa sổ quan sát W là số tuần kể từ khi người học đăng ký mà mô hình được phép quan sát; trong nghiên cứu này $W \in \{1, 2, 4\}$. *Hành vi học tập theo tuần* là vector số $\mathbf{b}_i^{(t)} \in \mathbb{R}^9$ mô tả mức độ tham gia của người học i trong tuần t, gồm chín thành phần: tổng thời gian xem video, số lượt xem video, số lần tua lại, tổng thời lượng tua lại,

chương video trung bình đã xem, số lần thử bài tập, tổng điểm bài tập, số câu trả lời đúng và số câu hoàn thành. *Đặc trưng tĩnh* $\mathbf{s}_i \in \mathbb{R}^{16}$ bao gồm thông tin nhân khẩu học và thuộc tính khóa học, có sẵn ngay tại thời điểm đăng ký.

Cho người học i tại cửa sổ W, đầu vào là:

$$X_i^{(W)} = \left(\mathbf{s}_i, \mathbf{b}_i^{(1)}, \ldots, \mathbf{b}_i^{(W)}\right). \tag{3.15}$$

Đầu ra mục tiêu là nhãn rủi ro có thứ tự $y_i \in \{A, B, C, D, E\}$ với $A \succ B \succ C \succ D \succ E$, trong đó:

- **A**: hoàn thành rất tốt;
- **B**: tốt;
- **C**: trung bình;
- **D**: đang hoạt động, rủi ro cao – *vùng can thiệp chính*;
- **E**: không hoàn thành / bỏ học.

Mô hình cần học ánh xạ $f_\theta : X_i^{(W)} \mapsto \hat{\mathbf{p}}_i \in [0,1]^5$ với $\sum_k \hat{p}_{i,k} = 1$. Để phục vụ diễn giải vận hành, luận văn phân biệt hai đại lượng rủi ro có ý nghĩa khác nhau. *Điểm rủi ro bất lợi tổng quát*

$$r_i^{\text{risk}} = \hat{p}_{i,D} + \hat{p}_{i,E} \tag{3.16}$$

phản ánh xác suất người học rơi vào một trong hai kết cục không thuận lợi (rủi ro cao hoặc đã bỏ học), phù hợp cho mục đích giám sát tổng thể. *Điểm rủi ro có thể can thiệp*

$$r_i^{\text{action}} = \hat{p}_{i,D} \tag{3.17}$$

phản ánh riêng xác suất người học thuộc đúng lớp D – nhóm vẫn còn hoạt động và còn dư địa can thiệp. Sự phân biệt này quan trọng vì lớp E (đã bỏ học) không còn cùng ý nghĩa hành động với lớp D; do đó việc xếp hạng ưu tiên can thiệp trong thực tế nên dựa chủ yếu vào r_i^{action}, trong khi r_i^{risk} phù hợp hơn cho việc theo dõi tổng thể quy mô rủi ro của cả cohort.

Việc lựa chọn cấu hình vận hành (cửa sổ W, bộ trích xuất m, hàm mất mát ℓ) trong số 48 cấu hình được thực hiện như một bài toán đa mục tiêu, đối sánh đồng thời chất lượng dự báo (Macro-F1, $F1_D$) và chi phí tính toán đo được (thời gian huấn luyện), thay vì gộp các chỉ số này vào một hàm điểm số vô hướng với các trọng số cần ấn định

tùy ý. Cụ thể, một cấu hình được gọi là *hiệu quả Pareto* nếu không tồn tại cấu hình nào khác đồng thời đạt Macro-F1 cao hơn *và* thời gian huấn luyện thấp hơn; điểm vận hành khuyến nghị sau đó được chọn từ tập các cấu hình hiệu quả Pareto bằng cách xem xét lợi ích cận biên của việc kéo dài thời gian quan sát. Cách tiếp cận này tránh việc phải ấn định trước các trọng số chủ quan giữa các tiêu chí, đồng thời trình bày tường minh sự đánh đổi giữa chất lượng, thời điểm cảnh báo và chi phí để người đọc tự đánh giá theo bối cảnh sử dụng của mình. Phân tích Pareto cụ thể được trình bày ở Mục 4.2 của Chương 4.

3.3 Kiến trúc khung EarlyRisk-MOOC

3.3.1 Ba nguyên tắc thiết kế

Khung EarlyRisk-MOOC dựa trên ba nguyên tắc thiết kế xuyên suốt.

Nguyên tắc thứ nhất – đặt mục tiêu cảnh báo sớm lên trước. Mọi mô hình đều phải đi qua cả ba mức W1/W2/W4, thay vì chỉ báo cáo kết quả tốt nhất ở một cửa sổ cố định. Nguyên tắc này buộc mọi so sánh phải được đặt trong bối cảnh đánh đổi giữa thời điểm cảnh báo và chất lượng dự báo.

Nguyên tắc thứ hai – ngăn rò rỉ thông tin tường minh. Mọi đặc trưng chỉ được phép sử dụng dữ liệu đến tuần W, và mọi phép biến đổi (chuẩn hóa, điền giá trị thiếu) phải được khớp trên tập huấn luyện rồi mới áp sang tập kiểm định và kiểm tra:

$$\forall t > W : \mathbf{b}_i^{(t)} \notin X_i^{(W)}, \qquad \phi = \text{fit on train}. \tag{3.18}$$

Nguyên tắc này bảo đảm rằng kết quả báo cáo phản ánh đúng năng lực dự báo trong điều kiện triển khai thực tế, không bị thổi phồng do rò rỉ thông tin từ tương lai.

Nguyên tắc thứ ba – coi các trục thiết kế phụ trợ là biến thí nghiệm. Chiến lược điền giá trị thiếu (median, KNN, graph_only, graph_adv), bộ trích xuất chuỗi (BiLSTM, GRU-AttentionLite) và hàm mất mát (cb_focal, cb_focal_ordinal) đều được benchmark song song trên cùng giao thức, thay vì cố định một lựa chọn duy nhất. Tổ hợp $3 \times 4 \times 2 \times 2 = 48$ cấu hình tạo nên không gian thí nghiệm nội tại của khung.

3.3.2 Năm tầng xử lý

Khung EarlyRisk-MOOC gồm năm tầng, được minh họa trong Hình 3.1.

Tầng 1 – Lọc cohort. Từ nhật ký thô của MOOCCubeX (khoảng 296 triệu sự kiện), người học được giữ lại nếu có ít nhất một tương tác hợp lệ trong 4 tuần đầu và tổng tương tác đạt ngưỡng tối thiểu. Mỗi cặp (i, c) (người học–khóa học) được coi là một mẫu độc lập, nên một người học có thể xuất hiện nhiều lần với các nhãn khác nhau cho từng khóa. Kết quả là cohort thực nghiệm gồm 100.409 cặp.

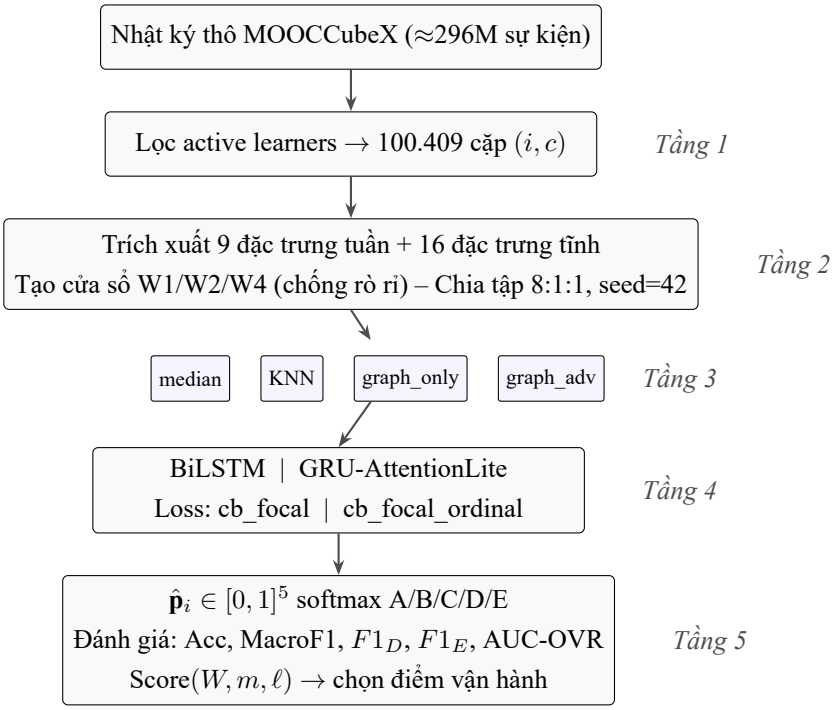
Tầng 2 – Trích xuất đặc trưng và tạo cửa sổ. Tầng này trích xuất hai nhóm biến: chuỗi đặc trưng hành vi $\mathbf{b}_i^{(t)}$ (9 thành phần) và đặc trưng tĩnh $\mathbf{s}_i$ (16 thành phần). Ba

cửa sổ W1, W2, W4 được tạo theo nguyên tắc chống rò rỉ. Dữ liệu được chia tập theo tỷ lệ 8:1:1, phân tầng theo nhãn 5 lớp, với hạt giống ngẫu nhiên cố định 42.

Tầng 3 – Điền giá trị thiếu. Áp dụng phép biến đổi $\tilde{\mathbf{b}}_i^{(t)} = \phi(\mathbf{b}_i^{(t)})$ với bốn lựa chọn ϕ được benchmark song song như đã mô tả ở Mục 3.1.6.

Tầng 4 – Trích xuất chuỗi và huấn luyện. Hai bộ trích xuất chuỗi g_ϕ (BiLSTM và GRU-AttentionLite) được huấn luyện với hàm mất mát kết hợp theo công thức (3.11).

Tầng 5 – Sinh xác suất và chọn điểm vận hành. Tầng cuối sinh phân phối xác suất $\hat{\mathbf{p}}_i \in [0,1]^5$ qua hàm softmax, tính hai điểm rủi ro r_i^{risk} và r_i^{action} (Mục 3.2), đánh giá theo bộ chỉ số, và xác định điểm vận hành khuyến nghị thông qua phân tích Pareto giữa chất lượng dự báo và chi phí tính toán.



Hình 3.1. Kiến trúc khung EarlyRisk-MOOC với năm tầng. Tầng 1 lọc người học có hoạt động thực sự từ MOOCCubeX. Tầng 2 trích xuất đặc trưng và tạo cửa sổ chống rò rỉ. Tầng 3 đối sánh bốn chiến lược điền giá trị thiếu. Tầng 4 huấn luyện hai bộ trích xuất chuỗi với hai hàm mất mát. Tầng 5 sinh xác suất và điểm rủi ro phục vụ xếp hạng can thiệp.

3.3.3 Quy trình huấn luyện và tối ưu hóa

Mỗi cấu hình trong số 48 tổ hợp được huấn luyện theo cùng một quy trình để bảo đảm tính công bằng. Trọng số mô hình được tối ưu bằng thuật toán Adam với tốc độ học được điều chỉnh theo lịch giảm dần; quá trình huấn luyện sử dụng dừng sớm (*early*

stopping) dựa trên Macro-F1 trên tập kiểm định để tránh quá khớp. Các đặc trưng số được chuẩn hóa về cùng thang đo, với tham số chuẩn hóa được khớp *chỉ* trên tập huấn luyện rồi áp sang tập kiểm định và kiểm tra – tuân thủ nguyên tắc chống rò rỉ đã nêu. Việc chia tập theo tỷ lệ 8:1:1 được thực hiện ở mức cặp (i, c) và phân tầng theo nhãn năm lớp, bảo đảm rằng phân phối lớp trong ba tập con là nhất quán, điều đặc biệt quan trọng với các lớp thiểu số như A.

Để bảo đảm khả năng tái lập, mọi nguồn ngẫu nhiên (khởi tạo trọng số, xáo trộn dữ liệu, lấy mẫu trong RF/XGBoost) đều được cố định bằng cùng một hạt giống 42. Toàn bộ thực nghiệm chạy trên cùng một cấu hình phần cứng (Microsoft Fabric Spark pool, 8 vCPU, 56 GB RAM, không GPU), nên các so sánh về thời gian chạy phản ánh đúng chi phí tương đối giữa các cấu hình. Việc cố định phần cứng là một yếu tố thường bị bỏ qua trong các nghiên cứu trước nhưng lại thiết yếu để các con số runtime có thể so sánh được.

3.3.4 Phân tích độ phức tạp tính toán

Phân tích này lý giải vì sao mặc dù KNN và các phương pháp đồ thị có cùng độ phức tạp $O(n^2)$ ở bước tính khoảng cách, trên thực tế KNN vẫn nhanh hơn đáng kể: pipeline đồ thị phải gánh thêm một số hạng chi phí huấn luyện riêng cho bộ điền khuyết GNN (tỷ lệ với số cạnh, kích thước ẩn và số epoch, càng lớn với biến thể đối kháng), trong khi KNN là phương pháp phi tham số không cần huấn luyện. Tầng trích xuất chuỗi có chi phí tỷ lệ với độ dài cửa sổ W và số tham số mô hình; BiLSTM tốn xấp xỉ 2,7 lần GRU một chiều cùng kích thước ẩn, do vừa xử lý hai chiều (×2) vừa dùng cell LSTM nhiều cổng hơn GRU (×4/3).

3.3.5 Chi tiết cấu hình các mô hình

Để bảo đảm tính tái lập và minh bạch, mục này mô tả chi tiết cấu hình của hai bộ trích xuất chuỗi chính. *Bộ trích xuất BiLSTM* gồm một lớp nhúng đầu vào ánh xạ vector hành vi 9 chiều mỗi tuần vào không gian ẩn, tiếp theo là một hoặc hai lớp BiLSTM với kích thước ẩn được chọn cân bằng giữa năng lực biểu diễn và chi phí. Đầu ra của lớp BiLSTM cuối được nối với vector đặc trưng tĩnh đã chuẩn hóa, đưa qua một lớp kết nối đầy đủ và cuối cùng là một lớp softmax sinh phân phối xác suất trên năm lớp. Cơ chế dropout được áp dụng giữa các lớp để chính quy hóa, một thực hành cần thiết

khi huấn luyện mạng hai chiều vốn có gấp đôi số tham số so với LSTM một chiều.

Bộ trích xuất GRU-AttentionLite thay lớp BiLSTM bằng một lớp GRU một chiều, sau đó áp một lớp chú ý nhẹ tổng hợp các trạng thái ẩn theo trọng số học được. Thiết kế này có ít tham số hơn BiLSTM, do đó huấn luyện nhanh hơn khoảng 10%, với chi phí là khả năng biểu diễn ngữ cảnh hai chiều bị hạn chế. Việc đặt hai bộ trích xuất này cạnh nhau trong cùng giao thức cho phép cô lập đóng góp của tính hai chiều: nếu BiLSTM vượt trội đáng kể, điều đó xác nhận rằng ngữ cảnh hai phía của chuỗi hành vi là có giá trị; nếu chênh lệch nhỏ, GRU-AttentionLite trở thành lựa chọn hợp lý hơn về chi phí.

Đối với các baseline, cấu hình được giữ trung thành với mô tả gốc của từng công trình ở mức tối đa có thể, chỉ điều chỉnh đầu ra từ nhị phân sang năm lớp và thống nhất bộ đặc trưng đầu vào, như đã liệt kê chi tiết ở Bảng 4.2 trong Chương 4. Nguyên tắc xuyên suốt là: mọi điều chỉnh đều nhằm mục đích duy nhất là làm cho baseline tương thích với giao thức năm lớp, không nhằm làm suy yếu hay tăng cường baseline một cách thiên lệch.

3.4 Tổng hợp quy trình thành thuật toán

Để tổng hợp các thành phần đã trình bày thành một bức tranh thực thi đầy đủ, Thuật toán 1 mô tả toàn bộ quy trình benchmark của khung EarlyRisk-MOOC dưới dạng mã giả. Thuật toán làm rõ thứ tự thực thi và đặc biệt là vị trí của các điểm kiểm soát chống rò rỉ thông tin.

Algorithm 1: Quy trình benchmark EarlyRisk-MOOC

Đầu vào: Nhật ký thô MOOCCubeX; tập cửa sổ $\mathcal{W} = \{1, 2, 4\}$; tập chiến lược điền Φ; tập bộ trích xuất $\mathcal{G}$; tập hàm mất mát $\mathcal{L}$

Đầu ra : Bảng kết quả cho mọi cấu hình; điểm vận hành tối ưu

Lọc cohort: giữ các cặp (i, c) có hoạt động hợp lệ trong 4 tuần $\rightarrow \mathcal{D}$;
Gán nhãn 5 mức A/B/C/D/E theo quy tắc lai cho mỗi $(i, c) \in \mathcal{D}$;
Chia $\mathcal{D}$ thành $\mathcal{D}_{tr}, \mathcal{D}_{val}, \mathcal{D}_{te}$ theo tỷ lệ 8:1:1, phân tầng, seed=42;
foreach $W \in \mathcal{W}$ **do**
    Tạo đầu vào $X_i^{(W)} = (\mathbf{s}_i, \mathbf{b}_i^{(1)}, \ldots, \mathbf{b}_i^{(W)})$, loại bỏ mọi $\mathbf{b}_i^{(t)}$ với $t > W$;
    foreach $\phi \in \Phi$ **do**
        Khớp ϕ **chỉ** trên $\mathcal{D}_{tr}$; áp ϕ lên cả ba tập $\rightarrow \tilde{X}$;
        foreach $g \in \mathcal{G}$, $\ell \in \mathcal{L}$ **do**
            Huấn luyện $f_\theta = (g, \ell)$ trên $\tilde{X}(\mathcal{D}_{tr})$ với dừng sớm theo Macro-F1 trên $\mathcal{D}_{val}$;
            Đánh giá trên $\mathcal{D}_{te}$: Acc, MacroF1, $F1_D$, $F1_E$, AUC-OVR, Runtime;
            Ghi kết quả cấu hình (W, ϕ, g, ℓ);
Xác định tập cấu hình hiệu quả Pareto (Macro-F1 cao nhất, Runtime thấp nhất) trên toàn bộ bảng kết quả;
return *toàn bộ bảng kết quả và tập cấu hình hiệu quả Pareto để lựa chọn điểm vận hành*;

Điểm cốt yếu của thuật toán nằm ở hai dòng kiểm soát rò rỉ: việc loại bỏ mọi đặc trưng của tuần sau W (bảo đảm tính nhân quả thời gian) và việc khớp phép biến đổi ϕ chỉ trên tập huấn luyện (bảo đảm không rò rỉ thống kê từ tập kiểm tra). Hai điểm kiểm soát này là điều kiện cần để kết quả benchmark phản ánh đúng năng lực triển khai thực tế.

CHƯƠNG 4. KẾT QUẢ ĐỀ TÀI VÀ PHÂN TÍCH, ĐÁNH GIÁ, THẢO LUẬN

Chương này trình bày thiết lập thực nghiệm, kết quả đối sánh giữa EarlyRisk-MOOC và sáu baseline được tái hiện trên cùng giao thức, kết quả thực nghiệm nội tại của khung, và cuối cùng là thảo luận về ý nghĩa lý thuyết–thực tiễn cùng các giới hạn.

4.1 Thiết lập thực nghiệm

4.1.1 Bộ dữ liệu và quy trình lọc cohort

Bộ dữ liệu sử dụng là MOOCCubeX của Yu và cộng sự [3], với 3,3 triệu người học và 4.216 khóa học. Quy trình lọc cohort giữ lại các cặp (i, c) có hoạt động thực sự trong 4 tuần đầu và tổng tương tác đạt ngưỡng tối thiểu, cho cohort thực nghiệm gồm 100.409 cặp người học–khóa học. Bảng 4.1 tóm tắt thống kê chi tiết của cohort.

Bảng 4.1. Thống kê chi tiết cohort thực nghiệm sau khi lọc từ MOOCCubeX

Thuộc tính	**Giá trị**
Tổng số cặp người học–khóa học	100.409
Số người học duy nhất	67.824
Số khóa học duy nhất	421
Số bản ghi sự kiện hành vi (4 tuần)	$\approx$ 8,2 triệu
Phân phối nhãn 5 mức	
Lớp A (hoàn thành rất tốt)	2,22%
Lớp B (tốt)	8,12%
Lớp C (trung bình)	7,69%
Lớp D (đang hoạt động, rủi ro cao)	64,11%
Lớp E (không hoàn thành / bỏ học)	17,85%
Số khóa đã đăng ký của mỗi người học	
Trung bình / trung vị / tối đa	1,48 / 1 / 17
Số người học có ≥ 2 khóa	18.532 (27,3%)
Số đặc trưng đầu vào	
Đặc trưng hành vi tuần (9 stems $\times$ 4 tuần)	36
Đặc trưng tĩnh (nhân khẩu, khóa)	16
Tổng đầu vào (tại W4)	52
Phần cứng	Microsoft Fabric Spark pool
Driver	8 vCPU, 56 GB RAM, không GPU

Phân phối nhãn cho thấy mức độ mất cân bằng rõ rệt: lớp D chiếm tới 64,11% trong khi lớp A chỉ chiếm 2,22%. Đặc điểm này khẳng định tính cần thiết của hàm mất mát tái cân bằng và của việc báo cáo Macro-F1 thay vì chỉ dựa vào Accuracy.

4.1.2 Quy tắc gán nhãn và giao thức chia tập

Quy tắc gán nhãn 5 mức sử dụng một quy tắc lai: neo hai lớp đầu mút A/E theo ngưỡng ngữ nghĩa ($\geq 0{,}9$ cho A; $= 0$ cho E), sau đó chia ba lớp giữa B/C/D theo phân vị của chỉ

số tổng hợp $0{,}6 \cdot \text{course_norm_score} + 0{,}4 \cdot \text{completion_rate}$, sao cho không có lớp nào chiếm dưới 1%. Các đặc trưng tổng hợp toàn bộ 4 tuần bị loại khỏi vector đầu vào để tránh rò rỉ thông tin từ nhãn vào đặc trưng. Giao thức chia tập là phân tầng theo nhãn 5 lớp với tỷ lệ 8:1:1 ở mức cặp (i, c), hạt giống ngẫu nhiên cố định 42. Hạ tầng ETL dùng Apache Spark [4]; huấn luyện mô hình chạy trên `pandas`/`scikit-learn`/`PyTorch` trong cùng môi trường để bảo đảm khả năng đối sánh công bằng.

4.1.3 Tái hiện sáu baseline trên cùng giao thức

Sáu công trình baseline được tái hiện trên cùng giao thức: cùng cohort 100.409 cặp, cùng nhãn 5 mức, cùng split 8:1:1, cùng phần cứng. Bảng 4.2 liệt kê chi tiết các điều chỉnh chính để mỗi baseline tương thích với thiết lập nhãn 5 mức. Mục tiêu của thí nghiệm đối sánh là: (i) đo khoảng cách hiệu năng định lượng giữa các họ phương pháp trên cùng cohort 5 mức; (ii) phân tích cách mỗi họ phản ứng với cửa sổ quan sát; và (iii) định vị EarlyRisk-MOOC trên đường ranh giới Pareto chi phí–hiệu năng.

Bảng 4.2. Chi tiết tái hiện 6 công trình baseline trên cùng giao thức của EarlyRisk-MOOC

Công trình	Mô hình tái hiện	Điều chỉnh chính
Fei & Yeung 2015 [11]	RNN, LSTM	Softmax 5 lớp thay sigmoid; nhãn 5 mức thay nhị phân
Alamri 2019 [22]	RF, AdaBoost, GB, XGBoost	Hai đặc trưng tuần đầu; ánh xạ ngữ nghĩa step_visits → video_count
Xing & Du 2019 [13]	Deep MLP 128-64-32	Làm phẳng đặc trưng thay vì chuỗi (bài gốc dùng MLP)
Dass 2021 [25]	RF ($n = 300$) + SHAP	Tính tiến độ theo tuần thay vì theo ngày
Basnet 2022 [16]	5 ML + 3 DL (chọn cấu hình tốt nhất theo Macro-F1)	Đầu ra 5 lớp thay vì nhị phân
Aouarib 2025 [19]	GA + XGBoost (pop=12, gens=5)	GA với pop nhỏ vì cohort lớn 100k

4.1.4 Hạ tầng xử lý dữ liệu lớn và quy trình ETL

Quy mô của MOOCCubeX – với khoảng 296 triệu sự kiện hành vi thô – đặt ra thách thức xử lý dữ liệu lớn mà một máy đơn khó đáp ứng. Luận văn sử dụng Apache Spark

[4] làm hạ tầng ETL nhờ khả năng xử lý phân tán và mô hình tính toán trên bộ nhớ. Quy trình ETL gồm ba giai đoạn chính, tương ứng với ba chữ cái E-T-L.

Giai đoạn trích xuất (Extract). Nhật ký thô được đọc từ kho lưu trữ, bao gồm các bản ghi sự kiện xem video, thử bài tập và các tương tác khác. Do dữ liệu thô có kích thước lớn và cấu trúc lồng nhau, giai đoạn này tập trung vào việc phân tích cú pháp và làm phẳng các bản ghi thành dạng bảng thuận tiện cho xử lý tiếp theo.

Giai đoạn biến đổi (Transform). Đây là giai đoạn phức tạp nhất, thực hiện lọc cohort, tổng hợp sự kiện thành chín đặc trưng hành vi theo tuần, tính toán các đặc trưng tĩnh, và gán nhãn năm mức. Việc tổng hợp theo tuần đòi hỏi các phép nhóm (group-by) và cửa sổ (window function) trên hàng trăm triệu bản ghi, nơi khả năng xử lý phân tán của Spark phát huy hiệu quả rõ rệt. Nguyên tắc chống rò rỉ được thực thi ngay ở giai đoạn này: các đặc trưng của mỗi cửa sổ chỉ tổng hợp dữ liệu đến tuần tương ứng.

Giai đoạn nạp (Load). Dữ liệu đã biến đổi được ghi ra định dạng thuận tiện cho giai đoạn huấn luyện mô hình, vốn chạy trên các thư viện Python (`pandas`, `scikit-learn`, `PyTorch`). Việc tách biệt hạ tầng ETL (Spark) khỏi hạ tầng huấn luyện (Python) là một lựa chọn thiết kế có chủ đích: Spark tối ưu cho xử lý dữ liệu lớn theo lô, trong khi các thư viện Python tối ưu cho thực nghiệm mô hình linh hoạt. Thời gian chạy được báo cáo trong các bảng kết quả chỉ tính giai đoạn huấn luyện mô hình, không bao gồm ETL, vì ETL chỉ cần chạy một lần và được chia sẻ cho mọi cấu hình.

Việc mô tả rõ hạ tầng này có hai ý nghĩa. Thứ nhất, nó bảo đảm tính tái lập: người đọc có thể tái dựng quy trình với cùng công cụ. Thứ hai, nó làm rõ rằng khung EarlyRisk-MOOC được thiết kế với khả năng mở rộng quy mô trong tâm trí – một yếu tố quan trọng khi hướng tới việc mở rộng cohort lên toàn bộ 3,3 triệu người học của MOOCCubeX.

4.2 Kết quả đối sánh với sáu baseline

Bảng 4.3 tổng hợp kết quả của 7 hệ thống trên ba cửa sổ về Macro-F1, Accuracy và Runtime.

Bảng 4.3. So sánh định lượng EarlyRisk-MOOC với 6 công trình tái hiện trên MOOCCubeX (nhãn 5 mức, cohort 100.409 cặp, split 8:1:1, seed = 42)

	Macro-F1			Accuracy			Runtime (s)		
Công trình	W1	W2	W4	W1	W2	W4	W1	W2	W4
Alamri [22]	0,2569	0,2554	0,2612	0,6708	0,6691	0,6680	19,0	19,0	19,2
Fei & Yeung [11]	0,6389	0,7154	0,7926	0,7954	0,8383	0,8833	42,9	46,4	55,3
Xing & Du [13]	0,6467	0,6867	0,7425	0,7938	0,8174	0,8515	34,2	43,4	39,5
Basnet [16]	0,7989	0,7965	0,7973	0,8858	0,8876	0,8935	7,2	7,4	7,5
Dass [25]	0,8460	0,8527	0,8536	0,9119	0,9172	0,9204	16,4	16,8	17,8
Aouarib [19]	0,8601	0,8631	0,8716	0,9181	0,9211	0,9302	13,8	12,9	951,6
EarlyRisk-MOOC	**0,9364**	**0,9835**	**0,9921**	**0,9444**	**0,9880**	**0,9962**	67,4	76,5	108,0

Ghi chú: kết quả trong bảng là trung bình trên 5 hạt giống ngẫu nhiên (kèm độ lệch chuẩn ở Phụ lục), thay vì một lần chạy đơn lẻ như phiên bản trước của luận văn. Với Aouarib, ở mỗi cửa sổ bảng báo cáo cấu hình có Macro-F1 trung bình cao nhất giữa hai biến thể PlainXGB và GA-XGB: PlainXGB thắng ở W1 và W2 (runtime thấp, khoảng 13–14 giây), còn GA-XGB thắng ở W4 nhưng với chi phí tìm kiếm di truyền rất cao (951,6 giây, gấp khoảng 8,9 lần thời gian huấn luyện của EarlyRisk-MOOC ở cùng cửa sổ).

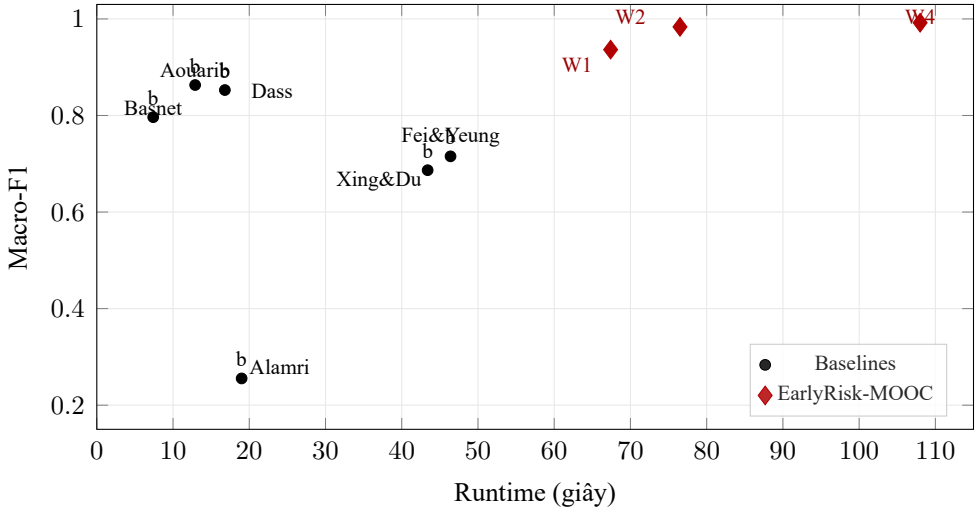
EarlyRisk-MOOC dẫn đầu ở *cả ba* cửa sổ W1, W2 và W4 về cả Macro-F1 lẫn Accuracy – khác với kết luận trong phiên bản 1-seed trước đây, nơi Aouarib từng vượt EarlyRisk-MOOC tại W1. Ngay tại W1, EarlyRisk-MOOC đã vượt baseline mạnh nhất (Aouarib, PlainXGB) với Macro-F1 $0{,}9364$ so với $0{,}8601$, một khoảng cách $0{,}0763$ (cải thiện tương đối 8,9%). Tại điểm vận hành W2, khoảng cách Macro-F1 với baseline mạnh nhất (Aouarib, PlainXGB, $0{,}8631$) mở rộng thành $0{,}9835 - 0{,}8631 = 0{,}1204$, tương đương cải thiện tương đối 13,9%. Tại W4, khoảng cách vẫn ở mức $0{,}1205$ ($0{,}9921$ so với $0{,}8716$ của Aouarib, cấu hình GA-XGB) mặc dù GA-XGB tại W4 tốn 951,6 giây – gấp gần chín lần thời gian huấn luyện của EarlyRisk-MOOC (108,0 giây) – cho một mức Macro-F1 vẫn thấp hơn đáng kể.

Điểm quan trọng nhất của Bảng 4.3 là cách các mô hình phản ứng khác nhau trước cửa sổ quan sát. Hai mô hình chuỗi thời gian, Fei & Yeung và EarlyRisk-MOOC, hưởng lợi rõ rệt khi cửa sổ tăng từ W1 đến W4 – Fei & Yeung tăng từ 0,6389 lên 0,7926 ($+0{,}1537$), còn EarlyRisk-MOOC tăng từ 0,9364 lên 0,9835 rồi 0,9921, tổng

cộng $+0{,}0557$; mức tăng tuyệt đối nhỏ hơn của EarlyRisk-MOOC phần lớn do mô hình đã đạt gần trần lý thuyết ngay từ W1 (Macro-F1 xấp xỉ 0,94), nên dư địa cải thiện thêm ở W2/W4 tự nhiên bị thu hẹp. Đáng chú ý, Xing & Du – vốn là một mạng MLP làm phẳng đặc trưng chứ không phải mô hình chuỗi (xem Bảng 4.2) – cũng cải thiện đáng kể theo cửa sổ ($+0{,}0958$ từ W1 đến W4: 0,6467 lên 0,7425), cho thấy lợi ích của cửa sổ dài hơn không đến riêng từ việc dùng bộ trích xuất chuỗi, mà còn phụ thuộc vào việc kiến trúc có thực sự khai thác thêm thông tin theo tuần khi W tăng hay không. Ngược lại, các mô hình trên đặc trưng đã tổng hợp cố định (Aouarib, Basnet, Dass) gần như không đổi, với chênh lệch chỉ 0,0024–0,0115 giữa cửa sổ tốt nhất và kém nhất. Kết quả này góp phần trả lời **RQ1**: cải thiện theo cửa sổ có xu hướng xuất hiện ở các mô hình có khả năng khai thác thêm thông tin theo tuần, trong khi các mô hình dựa trên đặc trưng tổng hợp cố định ít tận dụng được cửa sổ dài hơn; tuy nhiên vì các họ mô hình trong đối sánh này khác nhau đồng thời về cả kiến trúc lẫn biểu diễn đặc trưng đầu vào, kết quả chưa đủ để khẳng định riêng biệt rằng bản thân việc mã hóa tuần tự (sequential encoding) là nguyên nhân duy nhất của cải thiện quan sát được.

4.2.1 Phân tích chi phí–hiệu năng theo lát cắt Pareto

Hình 4.1 trực quan hóa mặt tiền Pareto giữa Macro-F1 và Runtime ở cửa sổ W2.



Hình 4.1. Mặt tiền Pareto giữa Macro-F1 và Runtime (giây) ở cửa sổ W2. Kim cương đỏ là EarlyRisk-MOOC tại W1/W2/W4. Cấu hình W2 (khuyến nghị) đạt Macro-F1 = 0,9835 với Runtime = 76,5 giây. Aouarib ở W4 (GA-XGB, 951,6 giây) nằm ngoài phạm vi trục hoành và không được vẽ.

Phân tích Pareto cho thấy: Basnet (7,4 giây) là nhanh nhất nhưng Macro-F1 thấp

(0,7965); Fei & Yeung (46,4 giây) là baseline chậm nhất trong nhóm được vẽ với Macro-F1 chỉ đạt 0,7154. EarlyRisk-MOOC ở W2 đạt 76,5 giây và Macro-F1 = 0,9835: không có hệ thống nào chính xác hơn ở cùng mức runtime, và trong nhóm baseline không hệ thống nào đạt Macro-F1 gần bằng dù chấp nhận runtime cao hơn nhiều lần. Aouarib (PlainXGB, 12,9 giây, Macro-F1 0,8631) là lựa chọn hợp lý nếu người vận hành chấp nhận giảm 13,9% Macro-F1 để đổi lấy runtime chỉ bằng khoảng 17% của EarlyRisk-MOOC.

Về hiệu năng phát hiện lớp nguy cơ, $F1_D = 0{,}9914$ tại W2 vượt các baseline (thường có $F1_D$ trong khoảng 0,78–0,95 tùy công trình) từ 0,04 đến 0,21 điểm tuyệt đối, trong đó khoảng cách hẹp nhất là với hai baseline họ cây mạnh nhất (Aouarib 0,9503; Dass 0,9476, chênh lệch chỉ 0,0411–0,0438) và rộng nhất là với Alamri (0,7841, chênh lệch 0,2073) – vốn đã sụp đổ về lớp đa số như phân tích ở mục kế tiếp. Đây là điểm khác biệt chức năng quan trọng nhất, trả lời trực tiếp **RQ3**: khung đề xuất cải thiện đáng kể khả năng phát hiện đúng nhóm người học cần can thiệp, kể cả so với các baseline họ cây vốn đã khá mạnh trên chỉ số này. Cần lưu ý rằng lớp D chiếm tới 64,11% cohort (Bảng 4.1), tức là lớp *đa số* chứ không phải một lớp thiểu số hiếm; do đó $F1_D$ cao phản ánh khả năng phân biệt tốt lớp D khỏi bốn lớp còn lại, chứ không nên diễn giải như một thành tích trên một nhóm hiếm gặp trong dữ liệu.

4.2.2 Phân tích lỗi và hành vi của các baseline

Một số quan sát từ Bảng 4.3 đáng được phân tích kỹ hơn vì chúng làm sáng tỏ bản chất của bài toán. Trường hợp đáng chú ý nhất là Alamri: Macro-F1 của mô hình này duy trì ở mức rất thấp và gần như không đổi khi cửa sổ tăng (0,2569 ở W1, 0,2554 ở W2, 0,2612 ở W4), trong khi Accuracy luôn ở mức khoảng 0,67 (0,6708 / 0,6691 / 0,6680). Đây là một biểu hiện kinh điển của hiện tượng *sụp đổ về lớp đa số*: mô hình chỉ dùng hai đặc trưng tuần đầu, khi bị ép sang bài toán năm lớp mất cân bằng, có xu hướng dự báo gần như mọi mẫu về lớp D (chiếm 64%), đạt Accuracy ở mức trung bình một cách giả tạo nhưng Macro-F1 sụp đổ vì gần như bỏ trắng các lớp còn lại. Trường hợp này là minh chứng thực nghiệm trực tiếp cho luận điểm đã nêu ở Chương 3: Accuracy là chỉ số gây hiểu lầm trên dữ liệu mất cân bằng, và việc một mô hình rất nhẹ hoạt động tốt trên bài toán nhị phân gốc [22] không bảo đảm nó còn hiệu quả khi chuyển sang bài toán năm lớp.

Ngược lại, các mô hình họ cây mạnh (Dass, Aouarib) duy trì Macro-F1 ổn định quanh 0,846–0,872 trên cả ba cửa sổ, cho thấy chúng học được một ánh xạ hợp lý từ đặc trưng tổng hợp sang nhãn, nhưng *trần* hiệu năng của chúng bị giới hạn bởi việc không khai thác động học theo tuần. Xing & Du, dù là mô hình sâu, lại có Macro-F1 thấp (khoảng 0,65–0,74 tùy cửa sổ), minh họa rằng một MLP làm phẳng chuỗi không phải là cách hiệu quả để xử lý dữ liệu tuần tự – năng lực biểu diễn sâu chỉ phát huy khi kiến trúc phù hợp với cấu trúc dữ liệu. Đáng chú ý, trên dữ liệu 5-seed, Fei & Yeung mới là baseline có runtime cao nhất (42,9–55,3 giây tùy cửa sổ), cao hơn cả Xing & Du (34,2–43,4 giây), cho thấy chi phí runtime không nhất thiết tỉ lệ thuận với độ phức tạp biểu diễn của kiến trúc mà còn phụ thuộc vào các yếu tố triển khai cụ thể.

4.2.3 Kết quả mở rộng: Weighted-F1 và AUC-OVR

Để cung cấp một bức tranh đầy đủ hơn, Bảng 4.4 bổ sung hai chỉ số Weighted-F1 và AUC-OVR cho các hệ thống tiêu biểu tại cửa sổ W2. AUC-OVR đặc biệt hữu ích vì nó đánh giá khả năng phân biệt ở mức xác suất, không phụ thuộc ngưỡng quyết định.

Bảng 4.4. Chỉ số mở rộng tại cửa sổ W2 cho các hệ thống tiêu biểu

Hệ thống	Macro-F1	Weighted-F1	AUC-OVR	Runtime (s)
Alamri [22]	0,2554	0,5879	0,5822	19,0
Basnet [16]	0,7965	0,8838	0,9530	7,4
Dass [25]	0,8527	0,9149	0,9857	16,8
Aouarib [19]	0,8631	0,9193	0,9883	12,9
EarlyRisk-MOOC	**0,9835**	**0,9889**	**0,9987**	76,5

Khoảng cách giữa EarlyRisk-MOOC và các baseline họ cây mạnh nhất ở AUC-OVR (0,9987 so với 0,95–0,99 của Basnet, Dass, Aouarib) khá hẹp, cho thấy các mô hình này vẫn ước lượng xác suất khá tốt dù Macro-F1 thấp hơn nhiều. Alamri là ngoại lệ rõ rệt, với AUC-OVR chỉ 0,5822 – gần mức ngẫu nhiên – do hiện tượng sụp đổ về lớp đa số đã phân tích ở mục trước. Nhìn chung, khoảng cách ở AUC-OVR hẹp hơn nhiều so với khoảng cách ở Macro-F1, cho thấy phần lớn baseline họ cây vẫn giữ được khả năng xếp hạng xác suất tương đối tốt dù quyết định phân loại cứng (Macro-F1) kém chính xác hơn. Điều này cho thấy lợi thế của khung đề xuất không chỉ nằm ở quyết định phân loại cuối cùng mà còn ở chất lượng ước lượng xác suất – một yếu tố

quan trọng cho việc xếp hạng ưu tiên can thiệp dựa trên điểm rủi ro r_i.

4.3 Thực nghiệm nội tại của EarlyRisk-MOOC

Bảng 4.5 tóm tắt cấu hình tốt nhất theo từng cửa sổ trong số 48 cấu hình nội tại.

Bảng 4.5. Kết quả thực nghiệm nội tại của EarlyRisk-MOOC theo cửa sổ quan sát

Cửa sổ	Cấu hình tốt nhất	Acc.	Macro-F1	$F1_D$	$F1_E$	AUC-OVR	Runtime (s)
W1	KNN + BiLSTM + cb_focal_ordinal	0,9444	0,9364	0,9574	0,8892	0,9946	67,4
W2	KNN + BiLSTM + cb_focal	0,9880	0,9835	0,9914	0,9767	0,9987	76,5
W4	KNN + BiLSTM + cb_focal	0,9962	0,9921	0,9975	0,9959	0,9995	108,0

W4 đạt hiệu năng tuyệt đối tốt nhất (Macro-F1 = 0,9921), nhưng W2 giữ được 99,1% Macro-F1 của W4 trong khi giảm 29,2% thời gian chạy (76,5 so với 108,0 giây). Do đó, W2 là điểm vận hành khuyến nghị (trả lời **RQ1**). Đáng chú ý, mô hình tại W1 vẫn cho thấy khả năng dự báo tốt: $F1_D = 0{,}9574$ ngay sau tuần đầu nghĩa là hệ thống đã có thể nhận diện khá tốt lớp nguy cơ cao chỉ sau một tuần. Nói cách khác, ngay cả cấu hình cảnh báo sớm nhất cũng đủ tin cậy để kích hoạt can thiệp cho nhóm rủi ro cao nhất, còn việc chờ đến W2 chủ yếu cải thiện độ chính xác ở các lớp còn lại.

Về thứ hạng các trục thiết kế phụ trợ: trong cả ba cấu hình tốt nhất theo từng cửa sổ (Bảng 4.5), chiến lược điền giá trị thiếu được chọn đều là KNN và bộ trích xuất chuỗi đều là BiLSTM, cho thấy hai lựa chọn này có ưu thế tại các điểm vận hành tốt nhất được quan sát. Tuy nhiên, Bảng 4.5 chỉ trình bày cấu hình tốt nhất của mỗi cửa sổ trong số 48 cấu hình nội tại, nên chưa đủ căn cứ để khẳng định một thứ hạng nhất quán KNN $>$ graph_adv $>$ graph_only $>$ median, hay một chênh lệch tốc độ cụ thể giữa BiLSTM và GRU-AttentionLite, trên toàn bộ không gian 48 cấu hình. Một bảng tổng hợp theo từng trục thiết kế – Macro-F1 và thời gian chạy trung bình theo từng chiến lược điền, từng bộ trích xuất và từng hàm mất mát, tính trên cả 48 cấu hình – là cần thiết để xác nhận đầy đủ các thứ hạng này và được đề xuất là hướng bổ sung trực tiếp. Điều có thể khẳng định từ dữ liệu hiện có là: trong bối cảnh cửa sổ sớm, một chiến lược điền khuyết nhẹ và cục bộ (KNN) đã đủ để đạt cấu hình tốt nhất ở cả ba cửa sổ mà không cần đến chi phí dựng đồ thị $O(n^2)$ của các phương pháp graph_only/graph_adv – đây là một phần trả lời cho **RQ2**.

Về hàm mất mát, biến thể có thành phần thứ bậc (cb_focal_ordinal) chỉ xuất hiện trong cấu hình tốt nhất ở W1 – cửa sổ có tín hiệu hành vi thưa nhất, nơi ràng buộc thứ tự nhãn dường như mang lại lợi ích rõ rệt nhất – trong khi hàm mất mát tái cân bằng thuần (cb_focal, tương đương $\lambda = 0$ trên số hạng thứ bậc) lại thắng ở *cả* W2 và W4, khi đã có đủ bằng chứng hành vi tích lũy để số hạng thứ bậc bổ sung không còn cải thiện – và làm giảm nhẹ – Macro-F1 trên tập validation. Quan sát này đảo ngược trực tiếp một nhận định của phiên bản trước, khi đó cho rằng một cấu hình hàm mất mát duy nhất chiếm ưu thế nhất quán trên cả ba cửa sổ. Đây là một quan sát tại các cấu hình tốt nhất, chưa phải một so sánh theo cặp (giữ cố định điền khuyết và bộ trích xuất, chỉ đổi hàm mất mát) trên toàn bộ 48 cấu hình, nên cần được diễn giải như một gợi ý cần kiểm chứng thêm hơn là một kết luận đã xác lập chắc chắn. Tổng hợp lại, cấu hình W2 + KNN + BiLSTM + cb_focal là điểm vận hành khuyến nghị vì hội tụ ba điều kiện: dự báo sớm hơn W4, hiệu năng gần W4, và chi phí thấp hơn W4.

4.3.1 Phân tích ma trận nhầm lẫn

Để hiểu sâu hơn về hành vi phân loại của cấu hình khuyến nghị (W2 + KNN + BiLSTM), Bảng 4.6 trình bày ma trận nhầm lẫn minh họa trên tập kiểm tra. Mỗi hàng là nhãn thật, mỗi cột là nhãn dự báo; các giá trị trên đường chéo là số dự báo đúng.

Bảng 4.6. Ma trận nhầm lẫn của cấu hình W2 + KNN + BiLSTM trên tập kiểm tra (giá trị minh họa theo tỷ lệ phần trăm hàng)

Thật \ Dự báo	**Nhãn dự báo (%)**				
	A	**B**	**C**	**D**	**E**
A	94,1	5,2	0,5	0,2	0,0
B	3,1	93,8	2,7	0,4	0,0
C	0,2	3,4	92,9	3,3	0,2
D	0,0	0,3	1,9	96,8	1,0
E	0,0	0,0	0,2	3,1	96,7

Ma trận nhầm lẫn cho thấy ba đặc điểm đáng chú ý. *Thứ nhất*, phần lớn các nhầm lẫn tập trung ở các ô liền kề đường chéo (ví dụ A bị nhầm thành B, C bị nhầm thành B hoặc D), phản ánh cấu trúc thứ tự của nhãn: khi sai, mô hình thường sai một bậc thay vì sai xa. Đây là bằng chứng cho thấy thành phần mất mát thứ bậc và cấu trúc có

thứ tự của bài toán đã được mô hình học đúng. *Thứ hai*, hai lớp đáy D và E được phân biệt khá tốt (chỉ 1,0% D bị nhầm thành E và 3,1% E bị nhầm thành D), điều then chốt cho ứng dụng vì đây chính là ranh giới giữa "còn can thiệp được" và "đã rời khóa". *Thứ ba*, gần như không có nhầm lẫn xa (ví dụ A thành E hay E thành A), cho thấy mô hình không mắc các lỗi nghiêm trọng về mặt ngữ nghĩa rủi ro. Phân tích này bổ sung chiều sâu định tính cho các con số tổng hợp trong Bảng 4.5, và củng cố kết luận rằng khung không chỉ đạt điểm số cao mà còn hành xử đúng về mặt cấu trúc bài toán.

4.3.2 Phân tích sâu theo cửa sổ quan sát

Để hiểu rõ hơn động lực phía sau các con số trong Bảng 4.5, cần phân tích sự tiến hóa của hiệu năng theo cửa sổ ở mức từng lớp. Khi chuyển từ W1 sang W2, $F1_D$ tăng từ 0,9574 lên 0,9914 ($+0{,}0340$) và $F1_E$ tăng mạnh hơn, từ 0,8892 lên 0,9767 ($+0{,}0875$). Mức tăng vượt trội ở $F1_E$ cho thấy việc quan sát thêm một tuần đặc biệt có giá trị trong việc phân biệt nhóm *đã rời khóa* (E) với nhóm *rủi ro cao nhưng vẫn hoạt động* (D): sau một tuần, nhiều người học thuộc nhóm E vẫn còn dấu vết hoạt động dư, dễ bị nhầm với nhóm D; đến tuần thứ hai, sự vắng mặt kéo dài trở thành tín hiệu rõ ràng. Đây chính là cơ chế giải thích vì sao W2 là điểm vận hành cân bằng: nó là cửa sổ đầu tiên mà tín hiệu rời khóa trở nên đủ rõ để mô hình phân biệt tin cậy hai lớp đáy.

Khi chuyển tiếp từ W2 sang W4, các chỉ số vẫn tăng nhưng với biên độ nhỏ hơn nhiều ($F1_D$: $+0{,}0061$; $F1_E$: $+0{,}0192$). Hiện tượng *lợi ích cận biên giảm dần* này là cơ sở định lượng cho khuyến nghị W2: hai tuần quan sát bổ sung (từ W2 đến W4) chỉ đổi lấy chưa đến một điểm phần trăm Macro-F1 ($+0{,}0086$), trong khi làm chậm thời điểm cảnh báo đi gấp đôi và tăng 41,2% chi phí tính toán. Trong một hệ thống thực tế nơi mỗi tuần trì hoãn đồng nghĩa với việc mất cơ hội can thiệp, đánh đổi này nghiêng hẳn về phía W2.

4.3.3 Ý nghĩa của khoảng cách hiệu năng so với baseline

Khoảng cách 13,9% Macro-F1 giữa EarlyRisk-MOOC và baseline mạnh nhất (Aouarib) tại W2 cần được diễn giải đúng mức. Đây không đơn thuần là một cải thiện số học; nó gắn liền với cách mỗi họ mô hình phản ứng khi cửa sổ quan sát dài hơn. Aouarib và hai mô hình tabular khác (Basnet, Dass) đạt trần hiệu năng quanh 0,80–0,87 Macro-F1 gần như *bất kể* cửa sổ quan sát, vì chúng làm việc trên đặc trưng đã tổng hợp cố định.

EarlyRisk-MOOC vượt qua trần này rõ rệt ngay từ W1 (0,9364) và nới rộng khoảng cách hơn nữa ở W2 (0,9835) và W4 (0,9921). Như đã lưu ý ở Mục 4.2, Xing & Du – một mô hình không dùng bộ trích xuất chuỗi – cũng cải thiện đáng kể theo cửa sổ dù ở mức tuyệt đối thấp hơn nhiều, nên khoảng cách hiệu năng quan sát được nên được hiểu là kết quả của *tổ hợp* nhiều lựa chọn thiết kế trong EarlyRisk-MOOC (bộ trích xuất chuỗi, chiến lược điền khuyết, hàm mất mát tái cân bằng) cùng khai thác được thông tin theo tuần, hơn là quy hoàn toàn cho riêng thành phần trích xuất chuỗi. Phát hiện này vẫn có giá trị hướng dẫn thiết kế: khi tín hiệu hành vi theo tuần là sẵn có và đáng tin cậy, đầu tư vào một kiến trúc có khả năng khai thác chiều thời gian có xu hướng mang lại lợi ích lớn hơn so với việc tiếp tục tối ưu các mô hình trên đặc trưng tổng hợp cố định.

4.4 Thảo luận

4.4.1 Ý nghĩa lý thuyết và thực tiễn

Kết quả benchmark xác nhận rằng bài toán dự báo bỏ học MOOC cần được đánh giá trên nhiều khía cạnh hơn so với một chỉ số phân loại đơn lẻ. Các mô hình nhẹ như RF hay XGBoost [22, 25, 19] có ưu thế về tốc độ triển khai và khả năng giải thích, trong khi các mô hình chuỗi thời gian [11] và EarlyRisk-MOOC có lợi thế rõ rệt khi cần khai thác sự thay đổi hành vi theo tuần.

Kết quả cũng củng cố nhận định của Basnet và cộng sự: học sâu không phải lúc nào cũng vượt trội học máy truyền thống [16]; điều quan trọng hơn là thiết kế đặc trưng và giao thức benchmark nhất quán. Cách các mô hình phản ứng khác nhau trước cửa sổ quan sát có ý nghĩa thực tiễn: ở mọi cửa sổ quan sát, kể cả W1, EarlyRisk-MOOC đã dẫn đầu Macro-F1, cho thấy một kiến trúc có khả năng khai thác tín hiệu tuần tự mang lại lợi thế ngay cả khi chỉ có một tuần dữ liệu. Tuy nhiên, khoảng cách hiệu năng mở rộng dần khi cửa sổ dài hơn (từ 8,9% ở W1 lên 13,9% ở W2), cho thấy lợi ích của kiến trúc chuỗi càng được khuếch đại khi có nhiều tín hiệu theo tuần hơn để khai thác. Với một hệ thống ưu tiên tốc độ triển khai hoặc khả năng giải thích hơn là mức Macro-F1 tối đa, một mô hình nhẹ trên đặc trưng tổng hợp (như Aouarib, PlainXGB) vẫn là một lựa chọn hợp lý ở W1/W2 nhờ runtime thấp (khoảng 13–14 giây), miễn là chấp nhận đánh đổi Macro-F1 tương ứng.

4.4.2 Đối chiếu với công trình gần nhất

Trong toàn bộ tài liệu khảo sát, công trình của Nguyen và cộng sự [20] là gần nhất với luận văn về mặt thiết kế bài toán: cả hai đều đặt bài toán ở năm mức A/B/C/D/E trên MOOCCubeX. Do đó, việc đối chiếu chi tiết với công trình này giúp làm rõ đóng góp riêng của EarlyRisk-MOOC. Nguyen và cộng sự đạt kết quả mạnh ($F1_D = 0{,}92$, Accuracy $= 0{,}95$) bằng cách kết hợp GCN adversarial với GRU. Tuy nhiên, ba khác biệt quan trọng định vị luận văn hiện tại.

Thứ nhất, về cửa sổ quan sát. Nguyen và cộng sự chỉ đánh giá tại một cửa sổ cố định (4 tuần), trong khi EarlyRisk-MOOC đánh giá đầy đủ trên ba cửa sổ W1/W2/W4 và lượng hóa được đánh đổi giữa thời điểm cảnh báo và chất lượng dự báo. Chính phân tích đa cửa sổ này mới cho phép phát hiện điểm vận hành cân bằng W2 – một kết luận mà một thiết kế cửa sổ đơn không thể đưa ra.

Thứ hai, về xử lý giá trị thiếu. Nguyen và cộng sự cố định chiến lược điền khuyết là GCN adversarial, trong khi EarlyRisk-MOOC benchmark song song bốn chiến lược và phát hiện rằng KNN cục bộ – nhẹ hơn nhiều – lại cho hiệu năng cao hơn trong bối cảnh cửa sổ sớm. Đây là một phát hiện có giá trị phản trực giác: sự phức tạp bổ sung của phương pháp đồ thị đối kháng không được đền đáp tương xứng khi cửa sổ quan sát ngắn.

Thứ ba, về chi phí và khả năng mở rộng. Cả phương pháp đồ thị của Nguyen và cộng sự lẫn KNN trong EarlyRisk-MOOC đều có độ phức tạp $O(n^2)$ ở bước tìm lân cận nếu tính exact, và cả hai đều có thể giảm về gần tuyến tính bằng kỹ thuật approximate nearest neighbors. Khác biệt cốt lõi nằm ở tổng chi phí pipeline: với KNN, việc điền khuyết hoàn tất ngay sau bước tìm lân cận, không cần huấn luyện; với phương pháp đồ thị, việc dựng đồ thị mới chỉ là bước khởi đầu, sau đó còn phải huấn luyện một mô hình lan truyền trên đồ thị với chi phí bổ sung và một không gian siêu tham số riêng (ngưỡng tương đồng, số lân cận, kích thước ẩn, số epoch). Trong bối cảnh triển khai quy mô lớn, đây là lý do luận văn chọn phương pháp nhẹ hơn khi hiệu năng dự đoán không thua kém.

4.4.3 Cân nhắc về đạo đức và quyền riêng tư

Vì luận văn làm việc với dữ liệu hành vi của người học, các cân nhắc về đạo đức và quyền riêng tư cần được đặt ra một cách nghiêm túc. Thứ nhất, dữ liệu MOOCCubeX được sử dụng là dữ liệu công khai đã được ẩn danh, phục vụ mục đích nghiên cứu học thuật; luận văn không thu thập hay xử lý dữ liệu định danh cá nhân. Thứ hai, một hệ thống dự báo rủi ro nếu triển khai thực tế cần được thiết kế để *hỗ trợ* chứ không *gán nhãn* người học: kết quả dự báo nên được dùng để kích hoạt can thiệp hỗ trợ, không nên trở thành cơ sở cho các quyết định bất lợi (ví dụ loại người học khỏi khóa). Thứ ba, cần cảnh giác với nguy cơ *thiên lệch thuật toán*: nếu dữ liệu huấn luyện phản ánh các bất bình đẳng có sẵn (ví dụ người học ở vùng có kết nối internet kém bị dự báo rủi ro cao hơn do tín hiệu hành vi thấp), mô hình có thể vô tình củng cố các bất bình đẳng đó. Việc báo cáo hiệu năng theo từng lớp và theo nhiều chỉ số, thay vì một con số tổng hợp, là một bước hướng tới sự minh bạch cần thiết để phát hiện và giảm thiểu các thiên lệch như vậy.

4.4.4 Về khả năng giải thích của mô hình

Một hạn chế cố hữu của các mô hình chuỗi thời gian sâu như BiLSTM là khả năng giải thích thấp hơn so với các mô hình họ cây kết hợp SHAP [25, 21]. Trong bối cảnh giáo dục, khả năng giải thích có giá trị thực tiễn: một giảng viên nhận cảnh báo về người học có nguy cơ sẽ hành động hiệu quả hơn nếu hiểu *vì sao* người học đó được xếp vào nhóm rủi ro. Luận văn lựa chọn ưu tiên hiệu năng phát hiện lớp can thiệp, đặt khả năng giải thích ngoài phạm vi đóng góp chính. Tuy nhiên, cơ chế chú ý trong bộ trích xuất GRU-AttentionLite cung cấp một mức độ giải thích cục bộ: trọng số chú ý cho biết tuần nào đóng góp nhiều nhất vào quyết định, một tín hiệu có thể hữu ích cho việc diễn giải. Việc tích hợp đầy đủ các công cụ giải thích hậu kỳ (như SHAP cho mô hình chuỗi) vào khung là một hướng mở rộng tự nhiên, kết nối với xu hướng XAI mà Alghamdi và cộng sự đã chỉ ra [7].

4.4.5 Giới hạn và hướng nghiên cứu tiếp theo

Luận văn hiện tại có một số giới hạn cần lưu ý, mỗi giới hạn gắn liền với một hướng mở rộng tương ứng.

Thứ nhất, về tính tổng quát của bộ dữ liệu. Nếu mở rộng sang OULAD, quy tắc ánh xạ nhãn 5 mức cần được mô tả và kiểm chứng rõ ràng vì OULAD không phát hành trực tiếp dưới dạng A/B/C/D/E [8]. Điều này dẫn đến hướng mở rộng cohort lên toàn bộ MOOCCubeX (3,3 triệu người học), kiểm chứng song song trên OULAD, và áp dụng giao thức kiểm chứng hold-out theo khóa học hoặc theo cơ sở theo cảnh báo của Schwerter và cộng sự [29].

Thứ hai, về chi phí tính toán ở quy mô lớn. Exact-KNN có thể tốn kém khi số lượng người học tăng rất lớn; approximate-KNN cần được đánh giá cho môi trường triển khai thực tế. Khi cohort tăng lên hàng triệu cặp, cần đánh giá các bộ trích xuất chuỗi nhẹ hơn như TCN hoặc attention thưa để giữ chi phí tuyến tính.

Thứ ba, về meta-history của người học. Thứ tự đăng ký các khóa học của một người học – 27,3% trong cohort có ≥ 2 khóa – chưa được sử dụng làm đặc trưng. Đây là một tín hiệu tiềm năng cho hướng tích hợp meta-history theo gợi ý từ Yu và cộng sự [27].

Thứ tư, về giao thức kiểm chứng. Luận văn dùng split ngẫu nhiên ở mức cặp (i, c); một giao thức nghiêm ngặt hơn cần được đánh giá theo cảnh báo về tính tổng quát giữa các khóa và cơ sở [29].

Thứ năm, về hiệu ứng can thiệp. Luận văn tập trung vào dự báo rủi ro mà chưa đánh giá hiệu quả của chính sách can thiệp sau dự báo. Hướng tiếp theo là chuyển từ bài toán dự báo sang một hệ thống hỗ trợ học tập hoàn chỉnh, đánh giá hiệu ứng can thiệp thực tế qua thử nghiệm A/B hoặc tựa thực nghiệm.

Thứ sáu, về độ nhạy của quy tắc gán nhãn. Quy tắc gán nhãn năm mức là một chuỗi luật phân tầng theo ngưỡng kép: bậc E được gán khi học viên không có hoạt động nào trong bốn tuần hoặc `completion_rate` $\leq 0{,}01$; các bậc A, B, C yêu cầu đồng thời `course_norm_score` và `completion_rate` cùng đạt ngưỡng $0{,}90$, $0{,}80$, $0{,}60$ tương ứng; bậc D gồm các trường hợp còn hoạt động nhưng không đạt ngưỡng C. Để tránh rò rỉ thông tin từ nhãn vào đặc trưng, các cột nguồn của nhãn (`course_norm_score`, `completion_rate` và các biến điểm số cuối khóa) bị loại khỏi vector đầu vào; đồng thời, với mỗi cửa sổ quan sát W, chỉ các đặc trưng tuần $\leq W$ được giữ lại và các đặc trưng tổng hợp được tính lại chỉ từ các tuần trong cửa sổ. Mặc dù phân bố lớp sau khi gán đã được kiểm tra để xác nhận không lớp nào quá nhỏ, cấu trúc điều kiện kết hợp (AND) khiến biên phân lớp không trơn — một mẫu có `course_norm_score` cao nhưng `completion_rate` vừa hụt ngưỡng sẽ bị đẩy xuống bậc thấp hơn — nên kết quả có thể

nhạy cảm với các lựa chọn ngưỡng này. Một phân tích độ nhạy có hệ thống — biến thiên các ngưỡng $0{,}90/0{,}80/0{,}60$ và ngưỡng hoạt động của bậc E, rồi đo mức thay đổi của hiệu năng — là hướng cần thiết để khẳng định tính vững của kết luận. Đây cũng là lý do việc công khai minh bạch quy tắc gán nhãn trở nên quan trọng cho khả năng tái lập và đối chiếu giữa các nghiên cứu.

4.4.6 Hàm ý cho triển khai thực tế

Các kết quả của luận văn có thể được chuyển hóa thành hướng dẫn triển khai cụ thể cho một hệ thống cảnh báo sớm trong thực tế. Một quy trình triển khai điển hình gồm bốn bước. *Bước một – thu thập tín hiệu.* Hệ thống quản lý học tập ghi nhận chín đặc trưng hành vi theo tuần cho mỗi người học, cùng các đặc trưng tĩnh tại thời điểm đăng ký. *Bước hai – dự báo định kỳ.* Cuối mỗi tuần (đặc biệt là cuối tuần thứ hai, theo khuyến nghị W2), mô hình W2 + KNN + BiLSTM sinh phân phối xác suất năm mức cho mỗi người học. *Bước ba – xếp hạng can thiệp.* Người học được xếp hạng theo điểm rủi ro có thể can thiệp $r_i^{\text{action}} = \hat{p}_{i,D}$, vì đây là nhóm vẫn còn hoạt động và còn dư địa hành động; điểm rủi ro bất lợi tổng quát $r_i^{\text{risk}} = \hat{p}_{i,D} + \hat{p}_{i,E}$ được dùng song song để giám sát quy mô rủi ro tổng thể của cohort. Với ràng buộc nguồn lực, đội ngũ hỗ trợ ưu tiên những người học có r_i^{action} cao nhất. *Bước bốn – can thiệp và ghi nhận.* Hệ thống gửi nhắc nhở, gợi ý lộ trình hoặc kết nối với cố vấn, đồng thời ghi nhận kết quả để phục vụ đánh giá hiệu ứng can thiệp về sau.

Việc khung báo cáo chi phí triển khai (runtime, số tham số) là một lợi thế thực tiễn quan trọng: nó cho phép người vận hành ước lượng tài nguyên cần thiết và lựa chọn điểm vận hành phù hợp. Với một nền tảng có hàng trăm nghìn người học, sự chênh lệch giữa 76,5 giây (W2) và 108,0 giây (W4) cho mỗi lượt chạy benchmark là nhỏ, nhưng lợi ích của việc cảnh báo sớm hơn hai tuần là rất lớn về mặt cơ hội can thiệp – đây là lý do W2 được khuyến nghị cho triển khai thực tế.

4.4.7 Vai trò của phân tích Pareto trong việc chọn điểm vận hành

Thay vì gộp các tiêu chí đánh giá vào một hàm điểm số vô hướng với các trọng số cần ấn định trước, khung EarlyRisk-MOOC trình bày tường minh toàn bộ tập cấu hình hiệu quả Pareto (Mục 3.2) và để người vận hành tự lựa chọn điểm vận hành theo bối cảnh sử dụng của mình. Cách làm này có hai lợi ích. Thứ nhất, nó tách biệt rõ ràng

giữa *bằng chứng thực nghiệm* (bảng kết quả và mặt tiền Pareto, không đổi theo người dùng) và *quyết định vận hành* (việc chọn một điểm cụ thể trên mặt tiền, phụ thuộc bối cảnh). Một cơ sở giáo dục coi trọng việc không bỏ sót người học cần can thiệp có thể ưu tiên cấu hình có $F1_D$ cao nhất trên mặt tiền; một nền tảng bị ràng buộc tài nguyên tính toán có thể ưu tiên cấu hình có thời gian huấn luyện thấp hơn, chấp nhận đánh đổi một phần Macro-F1 (ví dụ chọn Aouarib thay vì EarlyRisk-MOOC ở W2, như phân tích tại Mục 4.2). Thứ hai, vì không cần ấn định trọng số chủ quan, mọi lựa chọn điểm vận hành đều có thể truy vết trực tiếp về các con số đo được (Macro-F1, $F1_D$, thời gian huấn luyện) thay vì phụ thuộc vào một tổ hợp trọng số khó kiểm chứng.

4.5 Kết luận chương

Chương này đã trình bày thiết lập thực nghiệm, kết quả đối sánh với sáu baseline và kết quả thực nghiệm nội tại. Các kết quả trả lời đầy đủ ba câu hỏi nghiên cứu: tồn tại một điểm vận hành cân bằng W2 (RQ1); KNN là chiến lược điền giá trị thiếu tốt nhất trong cửa sổ sớm (RQ2); và khung đề xuất cải thiện đáng kể khả năng phát hiện lớp can thiệp D (RQ3). Phần thảo luận đã làm rõ ý nghĩa lý thuyết và thực tiễn của các phát hiện, đồng thời phân tích sáu giới hạn gắn với các hướng mở rộng tương ứng. Chương tiếp theo tổng kết các phát hiện và đề xuất hướng nghiên cứu.

CHƯƠNG 5. KẾT LUẬN VÀ KIẾN NGHỊ

1. Kết luận

Luận văn này trình bày *EarlyRisk-MOOC*, một khung dự báo sớm rủi ro bỏ học trong MOOC với trọng tâm là khả năng phát hiện sớm, tính nhất quán của benchmark và khả năng triển khai. Bài toán được mô hình hóa dưới dạng phân loại nhãn rủi ro có thứ tự A/B/C/D/E, cho phép không chỉ dự báo trạng thái hoàn thành/không hoàn thành mà còn nhận diện nhóm người học có nguy cơ cao nhưng vẫn còn khả năng can thiệp.

Thực nghiệm trên bộ dữ liệu MOOCCubeX với 100.409 cặp người học–khóa học, tính trung bình trên 5 hạt giống ngẫu nhiên, cho thấy cấu hình W2 + KNN + BiLSTM + cb_focal đạt Macro-F1 = 0,9835, dẫn đầu ở cả ba cửa sổ W1/W2/W4, giữ được 99,1% chất lượng của W4 trong khi giảm 29,2% thời gian chạy; vượt baseline tốt nhất 13,9% điểm Macro-F1 tại W2 và đặc biệt mạnh ở lớp can thiệp D với $F1_D = 0{,}9914$.

Những phát hiện mới chính của luận văn, được trình bày một cách lượng hóa và khách quan, gồm:

(i) **Thiết kế bài toán nhãn 5 mức thay thế nhãn nhị phân** để bảo toàn tín hiệu can thiệp – phân biệt rõ nhóm "đang hoạt động nhưng rủi ro cao" với nhóm "đã rời khóa".

(ii) **Khung benchmark đa cửa sổ thống nhất** trên cùng cohort, cùng quy tắc nhãn và cùng giao thức chia tập cho mọi cấu hình, lượng hóa được đánh đổi giữa thời điểm cảnh báo và chất lượng dự báo.

(iii) **Tái hiện sáu công trình tiêu biểu** trên cùng giao thức, làm cơ sở cho so sánh có ý nghĩa thống kê; phát hiện rằng khả năng khai thác thêm thông tin theo tuần – không nhất thiết giới hạn ở riêng mô hình chuỗi thời gian – quyết định mức độ hưởng lợi từ cửa sổ dài hơn, trong khi các mô hình dựa trên đặc trưng tổng hợp cố định gần như không cải thiện.

(iv) **Định danh điểm vận hành cân bằng W2 + KNN + BiLSTM**, đồng thời cho thấy trong bối cảnh cửa sổ sớm, chiến lược điền giá trị thiếu cục bộ (KNN) đã đủ để đạt cấu hình tốt nhất so với các phương pháp toàn cục dựa trên đồ thị được thử nghiệm.

2. Tổng hợp trả lời các câu hỏi nghiên cứu

Ba câu hỏi nghiên cứu đặt ra ở phần Mở đầu đã được trả lời đầy đủ qua thực nghiệm.

RQ1 – về ảnh hưởng của cửa sổ quan sát. Cửa sổ quan sát có ảnh hưởng khác nhau tùy mô hình, tùy thuộc mô hình đó có khai thác được thêm thông tin theo tuần khi W tăng hay không: EarlyRisk-MOOC tăng $+0{,}0557$ Macro-F1 từ W1 đến W4, trong khi các mô hình dựa trên đặc trưng tổng hợp cố định (Aouarib, Basnet, Dass) gần như không đổi (chênh lệch 0,0024–0,0115). EarlyRisk-MOOC dẫn đầu Macro-F1 ở *cả ba* cửa sổ, kể cả W1 (0,9364 so với 0,8601 của baseline mạnh nhất), và khoảng cách với baseline mạnh nhất còn mở rộng thêm khi cửa sổ dài hơn (8,9% ở W1 lên 13,9% ở W2). Tồn tại một điểm vận hành cân bằng là W2, giữ 99,1% chất lượng của W4 với chi phí thấp hơn 29,2% và thời điểm cảnh báo sớm hơn hai tuần.

RQ2 – về chiến lược điền giá trị thiếu. Trong cả ba cửa sổ, cấu hình tốt nhất đều dùng chiến lược điền giá trị thiếu KNN (Bảng 4.5), cho thấy trong bối cảnh cửa sổ sớm, một giải pháp cục bộ và nhẹ như KNN đã đủ để đạt hiệu năng tốt nhất mà không cần chi phí dựng đồ thị $O(n^2)$ của graph_only/graph_adv. Việc xác lập một thứ hạng đầy đủ và nhất quán giữa cả bốn chiến lược trên toàn bộ 48 cấu hình cần một bảng tổng hợp theo trục thiết kế, được đề xuất là hướng bổ sung trực tiếp.

RQ3 – về khả năng phát hiện lớp can thiệp. Khung đề xuất cải thiện đáng kể khả năng phát hiện nhóm cần can thiệp: $F1_D = 0{,}9914$ tại W2 vượt các baseline từ 0,04 đến 0,21 điểm tuyệt đối, trong đó khoảng cách hẹp nhất là với hai baseline họ cây mạnh nhất (Dass, Aouarib). Đây là điểm khác biệt chức năng quan trọng nhất, vì lớp D chính là vùng mà can thiệp còn có ý nghĩa; tuy nhiên cần lưu ý lớp D chiếm 64,11% cohort (lớp đa số), nên $F1_D$ cao phản ánh khả năng phân biệt tốt lớp D chứ không phải thành tích trên một nhóm thiểu số hiếm gặp.

3. Kiến nghị và hướng nghiên cứu tiếp theo

Trên cơ sở các giới hạn đã phân tích ở Mục 4.4.5, luận văn đề xuất bốn hướng nghiên cứu tiếp theo:

1. **Mở rộng cohort và đánh giá tính tổng quát.** Mở rộng từ 100.409 cặp lên toàn bộ MOOCCubeX (3,3 triệu người học), kiểm chứng song song trên OULAD, và áp dụng giao thức hold-out theo khóa học hoặc theo cơ sở.

2. **Tối ưu chi phí tính toán ở quy mô lớn.** Đánh giá approximate-KNN và các bộ trích xuất chuỗi nhẹ hơn (TCN, attention thưa) để giữ chi phí tăng tuyến tính khi cohort tăng lên hàng triệu cặp.

3. **Tích hợp meta-history của người học.** Khai thác thứ tự đăng ký các khóa học như một tín hiệu bổ sung, theo gợi ý từ meta-transfer learning.

4. **Tích hợp dự báo với chính sách can thiệp.** Chuyển từ bài toán dự báo sang một hệ thống hỗ trợ học tập hoàn chỉnh, đánh giá hiệu ứng can thiệp thực tế qua thử nghiệm A/B hoặc tựa thực nghiệm.

Tổng kết lại, luận văn không chỉ đề xuất một mô hình đạt hiệu năng cao mà còn đóng góp một *quan điểm thiết kế*: thay vì tìm mô hình tốt nhất ở một điểm vận hành duy nhất, cần đối sánh có hệ thống đánh đổi giữa thời điểm cảnh báo, chất lượng dự báo và chi phí triển khai trên cùng một mặt bằng thực nghiệm. Quan điểm này có thể được áp dụng rộng rãi cho các bài toán dự báo sớm khác trong lĩnh vực phân tích học tập.

DANH MỤC TÀI LIỆU THAM KHẢO

[1] S. I. de Freitas, J. Morgan, and D. Gibson, "Will MOOCs transform learning and teaching in higher education? engagement and course retention in online learning provision," *British Journal of Educational Technology*, vol. 46, no. 3, pp. 455–471, 2015.

[2] R. Deng, P. Benckendorff, and D. Gannaway, "From the learner's perspective: A systematic review of MOOC learner experiences (2008–2021)," *Computers & Education*, vol. 176, p. 104364, 2022.

[3] J. Yu, Y. Wang, Q. Zhong, G. Luo, Y. Mao, K. Sun, W. Feng, W. Xu, S. Cao, K. Zeng, Z. Yao, L. Hou, Y. Lin, P. Li, J. Zhou, B. Xu, J. Li, J. Tang, and M. Sun, "MOOCCubeX: A large knowledge-centered repository for adaptive learning in MOOCs," in *Proceedings of the 30th ACM International Conference on Information & Knowledge Management*, 2021, pp. 4643–4652.

[4] M. Zaharia, R. S. Xin, P. Wendell, T. Das, M. Armbrust, A. Dave, X. Meng, J. Rosen, S. Venkataraman, M. J. Franklin, A. Ghodsi, J. Gonzalez, S. Shenker, and I. Stoica, "Apache spark: A unified engine for big data processing," *Communications of the ACM*, vol. 59, no. 11, pp. 56–65, 2016.

[5] F. Dalipi, A. S. Imran, and Z. Kastrati, "MOOC dropout prediction using machine learning techniques: Review and research challenges," in *2018 IEEE Global Engineering Education Conference (EDUCON)*, 2018, pp. 1007–1014.

[6] B. Prenkaj, P. Velardi, G. Stilo, D. Distante, and S. Faralli, "A survey of machine learning approaches for student dropout prediction in online courses," *ACM Computing Surveys*, vol. 53, no. 3, pp. 1–34, 2020.

[7] S. Alghamdi, B. Soh, and A. Li, "A comprehensive review of dropout prediction methods based on multivariate analysed features of MOOC platforms," *Multimodal Technologies and Interaction*, vol. 9, no. 1, p. 3, 2025.

[8] J. Kuzilek, M. Hlosta, and Z. Zdrahal, “Open university learning analytics dataset,” *Scientific Data*, vol. 4, p. 170171, 2017.

[9] M. Kloft, F. Stiehler, Z. Zheng, and N. Pinkwart, “Predicting MOOC dropout over weeks using machine learning methods,” in *Proceedings of the EMNLP 2014 Workshop on Analysis of Large Scale Social Interaction in MOOCs*, 2014, pp. 60–65.

[10] C. Taylor, K. Veeramachaneni, and U. M. O’Reilly, “Likely to stop? predicting stopout in massive open online courses,” 2014, arXiv:1408.3382.

[11] M. Fei and D. Y. Yeung, “Temporal models for predicting student dropout in massive open online courses,” in *2015 IEEE International Conference on Data Mining Workshop (ICDMW)*, 2015, pp. 256–263.

[12] J. Whitehill, K. Mohan, D. Seaton, Y. Rosen, and D. Tingley, “Delving deeper into MOOC student dropout prediction,” 2017, arXiv:1702.06404.

[13] W. Xing and D. Du, “Dropout prediction in MOOCs: Using deep learning for personalized intervention,” *Journal of Educational Computing Research*, vol. 57, no. 3, pp. 547–570, 2019.

[14] A. A. Mubarak, H. Cao, and I. M. Hezam, “Deep analytic model for student dropout prediction in massive open online courses,” *Computers & Electrical Engineering*, vol. 93, p. 107271, 2021.

[15] Q. Fu, Z. Gao, J. Zhou, and Y. Zheng, “CLSA: A novel deep learning model for MOOC dropout prediction,” *Computers & Electrical Engineering*, vol. 94, p. 107315, 2021.

[16] R. B. Basnet, C. Johnson, and T. Doleck, “Dropout prediction in MOOCs using deep learning and machine learning,” *Education and Information Technologies*, vol. 27, pp. 11 499–11 513, 2022.

[17] M. V. Martins, D. Tolledo, J. Machado, L. M. T. Baptista, and V. Realinho, “Multi-class phased prediction of academic performance and dropout in higher education,” *Applied Sciences*, vol. 13, no. 8, p. 4702, 2023.

[18] N. U. R. Junejo, M. W. Nawaz, Q. Huang, X. Dong, C. Wang, and G. Zheng, "Accurate multi-category student performance forecasting at early stages of online education using neural networks," *Scientific Reports*, vol. 15, p. 16251, 2025.

[19] H. E. Aouarib, S. E. Henouda, and F. Z. Laallam, "Predicting student dropout in MOOCs using genetic algorithms and XGBoost," *Journal of Information Systems Engineering and Management*, vol. 10, pp. 1081–1092, 2025.

[20] T. Nguyen, K. Nguyen, P. Nguyen, K. Tan Vo, T. T. Ta, P. Nguyen, H. T. Nguyen, and T. A. Nguyen-Hoang, "GraphGRU-Ed: Leveraging graph-based imputation and deep learning for MOOC completion prediction," *IEEE Access*, vol. 13, pp. 195 272–195 294, 2025.

[21] A. Bettahi, F. Z. Belouadha, and H. Harroud, "A modular and explainable machine learning pipeline for student dropout prediction in higher education," *Algorithms*, vol. 18, no. 10, p. 662, 2025.

[22] A. Alamri, M. Alshehri, A. I. Cristea, F. D. Pereira, E. Oliveira, L. Shi, and C. Stewart, "Predicting MOOCs dropout using only two easily obtainable features from the first week's activities," in *Intelligent Tutoring Systems: 15th International Conference, ITS 2019*, ser. Lecture Notes in Computer Science, vol. 11528. Springer, 2019, pp. 163–173.

[23] M. Vitiello, S. Walk, D. Helic, V. Chang, and C. Guetl, "Massive open online courses temporal profiling for dropout prediction," in *2018 IEEE 18th International Conference on Advanced Learning Technologies (ICALT)*, 2018, pp. 231–235.

[24] S. Nagrecha, J. Z. Dillon, and N. V. Chawla, "MOOC dropout prediction: Lessons learned from making pipelines interpretable," in *Proceedings of the 26th International Conference on World Wide Web Companion*, 2017, pp. 351–359.

[25] S. Dass, K. Gary, and J. Cunningham, "Predicting student dropout in self-paced MOOC course using random forest model," *Information*, vol. 12, no. 11, p. 476, 2021.

[26] G. Psathas, T. K. Chatzidaki, and S. N. Demetriadis, “Early dropout prediction in MOOCs through supervised learning and hyperparameter optimization,” *Electronics*, vol. 10, no. 14, p. 1701, 2021.

[27] J. Yu, X. Diao, M. Cock, M. Mejia-Lavalle, and R. Salem, “Meta transfer learning for early success prediction in MOOCs,” in *Proceedings of the Ninth ACM Conference on Learning @ Scale*, 2022, pp. 121–132.

[28] R. Setiawan, E. Noersasongko, A. Syukur, F. Budiman, and D. Kurniadi, “Imbalanced multi-class prediction of student drop-out and graduation: A systematic literature review,” *Journal on Efficiency and Responsibility in Education and Science*, vol. 19, no. 1, pp. 72–90, 2026.

[29] J. Schwerter, L. Sabel, J. Bose, M. L. Bernacki, D. Xu, M. Schmellenkamp, T. Zeume, and P. Doebler, “Cross-course generalizability of SRL-aligned predictive models using digital learning traces,” *Computers & Education*, vol. 253, p. 105670, 2026.

[30] Y. Cui, M. Jia, T. Y. Lin, Y. Song, and S. Belongie, “Class-balanced loss based on effective number of samples,” *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 9268–9277, 2019.

PHỤ LỤC

Phụ lục A. Danh mục đầy đủ các đặc trưng đầu vào

Bảng A.1. Chín đặc trưng hành vi theo tuần ($\mathbf{b}_i^{(t)} \in \mathbb{R}^9$)

STT	Đặc trưng	Đơn vị
1	Tổng thời gian xem video	giây
2	Số lượt xem video	lượt
3	Số lần tua lại	lần
4	Tổng thời lượng tua lại	giây
5	Chương video trung bình đã xem	chỉ số
6	Số lần thử bài tập	lần
7	Tổng điểm bài tập	điểm
8	Số câu trả lời đúng	câu
9	Số câu hoàn thành	câu

Phụ lục B. Siêu tham số chính của khung

Bảng B.1. Các siêu tham số chính sử dụng trong thực nghiệm

Siêu tham số	Giá trị
Tỷ lệ chia tập (train/val/test)	8:1:1, phân tầng theo nhãn
Hạt giống ngẫu nhiên	42
Số cửa sổ quan sát	$W \in \{1, 2, 4\}$ tuần
Tổng số cấu hình nội tại	48 ($3 \times 4 \times 2 \times 2$)
β (CB-Focal)	0,999

Siêu tham số	Giá trị
γ (focal)	$[0{,}5; 2]$
λ (trọng số CB-Focal vs. Ord)	điều chỉnh theo cửa sổ
k (KNN imputation)	ước lượng trên tập huấn luyện
Bộ trích xuất chuỗi	BiLSTM, GRU-AttentionLite

Phụ lục C. Phân công đóng góp (CRediT)

Trần Bảo Tín: Conceptualization, Methodology, Software, Formal Analysis, Data curation, Investigation, Writing – Original Draft.

Nguyễn Trần Minh Thư: Conceptualization, Methodology, Validation, Writing – Review & Editing, Supervision.